Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №1:

«Гистограммы и плотности распределений»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи 3
Теоретическая часть 3
Реализация 4
Результаты 5
Обсуждение 7
Выводы 8
Список литературы 8
Приложение 9

Постановка задачи

Цель этой работы - на практике разобраться, как эмпирические данные (выборка) соотносятся с теоретическими законами распределения. Мы исследуем пять разных случайных величин: Нормальное, Коши, Лапласа, Пуассона и Равномерное. Для каждой из них нужно сгенерировать выборки объемом 10, 100 и 1000 элементов, а затем визуализировать их, наложив гистограмму выборки на теоретическую кривую плотности.

Главная задача - проследить, как меняется картина с увеличением объема данных. Нужно увидеть, как хаотичный набор столбиков при малой выборке постепенно превращается в узнаваемую форму распределения при большой. Попутно необходимо решить проблему выбора количества интервалов (бинов) для гистограммы: их должно быть ровно столько, чтобы график был информативным, не терял детали, но и не превращался в «шум» из пустых промежутков.

Теоретическая часть

В данной работе мы сравниваем эмпирическое распределение (полученное из сгенерированной выборки) с теоретическим. Для непрерывных случайных величин основной характеристикой является функция плотности вероятности $f(x)$, а для дискретных — вероятность принятия конкретного значения $P(X = k)$.

Ниже приведены аналитические выражения для плотностей (и вероятностей) пяти исследуемых распределений с учетом заданных параметров.

1. Нормальное распределение
   Стандартное нормальное распределение $N(0,1)$ характеризуется параметрами $\mu = 0$ (сдвиг) и $\sigma = 1$ (масштаб). Плотность вероятности описывается формулой Гаусса:
   $$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$
2. Распределение Коши
   Распределение Коши $C(0,1)$ с параметрами сдвига $x_0 = 0$ и масштаба $\gamma = 1$. Это распределение известно своими «тяжелыми хвостами», из-за чего у него не определены математическое ожидание и дисперсия. Плотность имеет вид:
   $$f(x) = \frac{1}{\pi(1 + x^2)}$$

3. Распределение Лапласа

   Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$ с коэффициентами масштаба $b = \frac{1}{\sqrt{2}}$ и сдвигом $\mu = 0$. Его график напоминает два экспоненциальных спада, соединенных в острой вершине. Формула плотности:

$$f(x) = \frac{\sqrt{2}}{2} e^{-\sqrt{2}|x|}$$

4. Распределение Пуассона

   Это единственное дискретное распределение в работе. Случайная величина принимает только целые неотрицательные значения k. Для параметра $\lambda = 10$ вероятность выпадения числа k вычисляется как:

$$P(X = k) = \frac{10^k}{k!} e^{-10}$$

5. Равномерное распределение

   Непрерывное равномерное распределение $U(a, b)$ на отрезке $\left[-\sqrt{3}, \sqrt{3}\right]$. Длина интервала составляет $2\sqrt{3}$. Плотность вероятности постоянна внутри интервала и равна нулю вне его:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, x \in \left[-\sqrt{3}, \sqrt{3}\right] \\ 0, x \notin \left[-\sqrt{3}, \sqrt{3}\right] \end{cases}$$

Для визуализации выборки используется гистограмма. Диапазон значений разбивается на k интервалов (бинов). Высота каждого столбца рассчитывается так, чтобы площадь всей гистограммы была равна единице (условие нормировки `density=True`). Это позволяет сравнивать гистограмму напрямую с теоретической плотностью $f(x)$.

Выбор количества интервалов в программе осуществляется автоматически (правило Фридмана-Диакониса или стерджесса), что позволяет адаптировать детализацию графика под объем выборки n: для малых n берется меньше широких интервалов, чтобы сгладить шум, для больших n - больше узких, чтобы показать детали формы распределения.

Реализация

Разработка выполнена на языке Python с использованием трех основных библиотек: `numpy` (для работы с массивами), `scipy.stats` (для генерации распределений) и `matplotlib` (для визуализации).

Программа структурирована через конфигурационный список словарей. В нем для каждого из пяти заданных распределений инициализирован соответствующий объект из модуля `scipy.stats` (например, `stats.norm`, `stats.cauchy`). Там же заданы параметры распределений (математическое ожидание, среднеквадратическое отклонение, границы для равномерного и т.д.) и фиксированные пределы отрисовки графиков по оси X, чтобы исключить влияние редких экстремальных выбросов на визуализацию (что особенно критично для распределения Коши).

Логика скрипта построена на вложенном цикле. На верхнем уровне перебираются распределения, для каждого создается фигура с тремя областями (подосями). Во внутреннем цикле перебираются объемы выборок ($n = 10, 100, 1000$). Генерация случайных данных осуществляется методом `rv.rvs(size=n)`. Для построения теоретической кривой используются методы `rv.pdf(x)` (функция плотности для непрерывных величин) и `rv.pmf(x)` (функция массы для дискретных, таких как Пуассон).

Ключевым аспектом является построение гистограмм с использованием метода `plt.hist()`. Ему передаются два важных параметра: `density=True`, который нормирует площадь гистограммы к единице (превращая абсолютные частоты в плотность вероятности), и `bins='auto'`. Использование автоматического режима auto позволяет алгоритму самостоятельно рассчитывать оптимальное количество интервалов в зависимости от дисперсии данных и размера выборки (обычно на основе формулы Фридмана-Диакониса). Это решает проблему переизбытка пустого пространства при $n = 10$ и недостаточной детализации при $n = 1000$. В конце цикла готовая визуализация с тремя совмещенными графиками автоматически экспортируется в файл формата PNG.

Результаты

Ниже представлены гистограммы распределений сгенерированных выборок (синие столбики) и наложенные на них теоретические кривые плотностей распределений (красные линии).

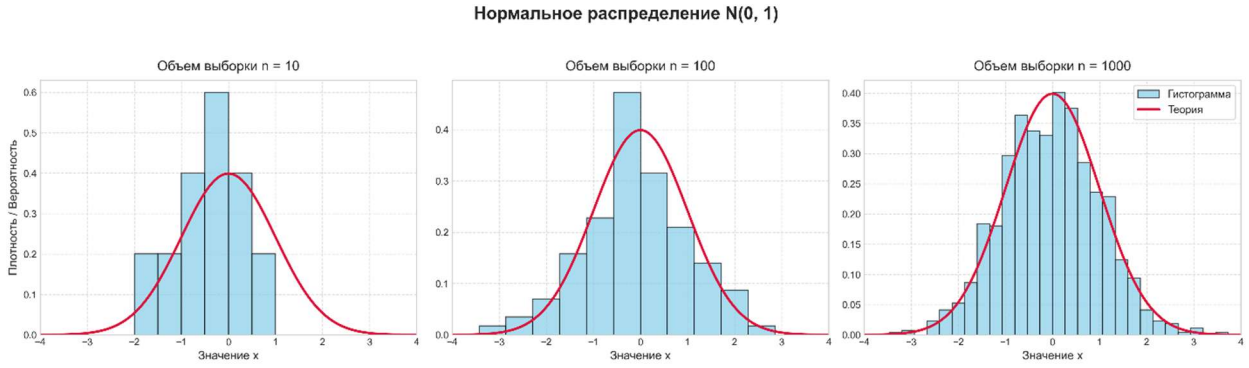

Рис. 1: Нормальное распределение

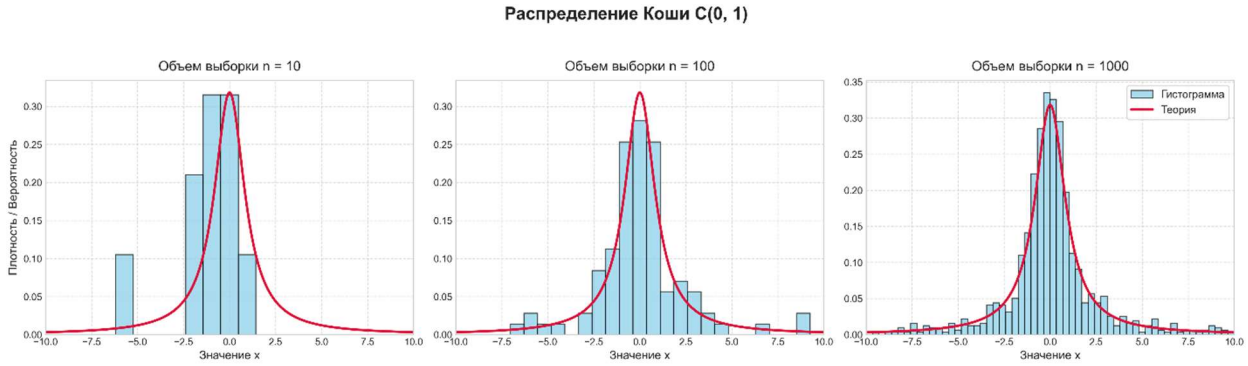

Рис 2. Распределение Коши

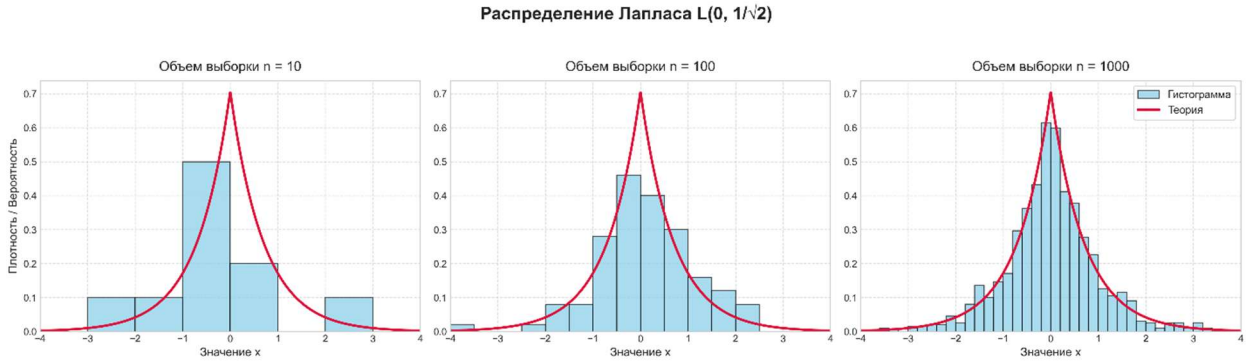

Рис 3. Распределение Лапласа

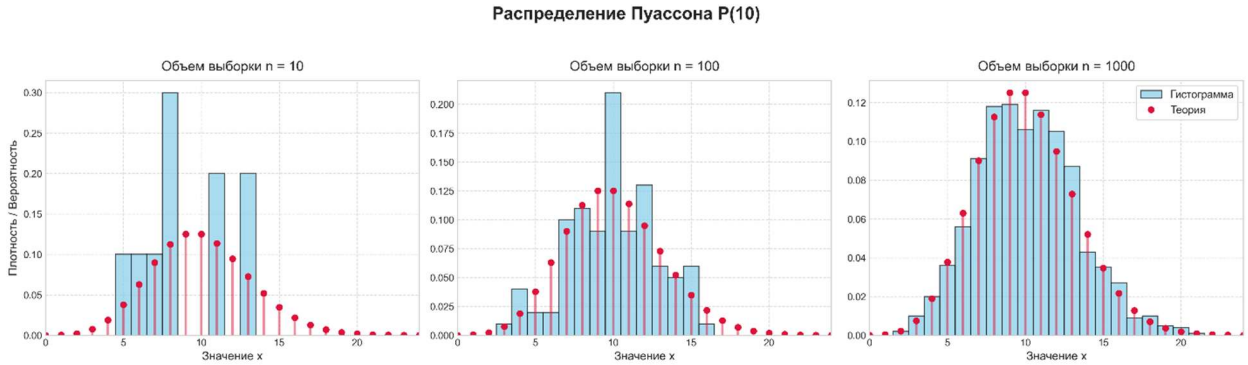

Рис 4. Распределение Пуассона

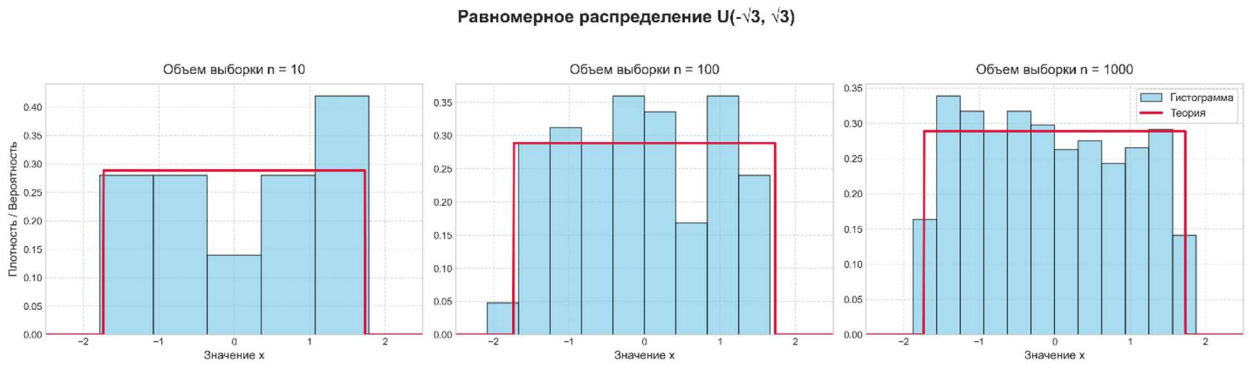

Рис 5. Равномерное распределение

Обсуждение

Анализируя полученные графики, в первую очередь бросается в глаза колоссальное влияние объема выборки на информативность гистограммы. На всех графиках при $n = 10$ мы видим скорее статистический шум, чем реальный закон распределения. Столбцы гистограмм формируются хаотично, образуя пустоты и необоснованные пики. Опираясь только на графики с десятью элементами, практически невозможно визуально отличить, например, нормальное распределение от распределения Лапласа. Это наглядно демонстрирует, почему в статистике малые выборки требуют применения особых, более сложных критериев оценки.

По мере увеличения объема данных до $n = 100$ начинает прорисовываться "скелет" распределений, однако дисперсия высот столбцов все еще велика. Только при $n = 1000$ эмпирические гистограммы начинают почти идеально огибать красные теоретические кривые. При этом хорошо заметно, как алгоритм автоматического выбора бинов адаптируется к данным: на малых выборках ширина интервалов большая, чтобы хоть как-то сгруппировать редкие данные, а на тысяче элементов столбцы становятся узкими, позволяя детально рассмотреть форму графика.

Сравнение распределений между собой на больших выборках ($n = 1000$) позволяет четко увидеть их аналитические особенности. Например, если сравнить нормальное распределение и распределение Лапласа, хорошо видно различие в их вершинах: гауссиана имеет мягкий, закругленный купол, тогда как график Лапласа образует характерный острый пик.

Особый интерес представляет график распределения Коши. В отличие от нормального закона, где при $n = 1000$ все данные компактно собрались вокруг центра, у распределения Коши даже на большой выборке четко видны "тяжелые хвосты". На краях графика (в районе значений -7.5 или +5) появляются одиночные островки данных. Это прекрасная визуализация того факта, что для Коши характерно регулярное появление экстремальных выбросов, из-за которых у него не существует математического ожидания.

Графики равномерного распределения ломают интуитивное представление о том, что "случайное" означает "одинаковое". Даже при $n = 100$ гистограмма больше похожа на неровный городской горизонт с высокими небоскребами и провалами, а не на ровную полку. Только при тысяче испытаний распределение начинает формировать характерный прямоугольник, хотя небольшая "волнистость" на верхней грани все равно сохраняется.

Что касается дискретного распределения Пуассона, выбранный формат визуализации с выравниванием бинов по целым числам позволил корректно сопоставить площади столбцов с теоретическими вероятностями (красными точками). Интересно отметить, что при параметре $\lambda = 10$ гистограмма Пуассона визуально приобретает колоколообразную форму, демонстрируя свойство сходимости к нормальному распределению при увеличении значения параметра.

Выводы

1. Влияние объема выборки: Эмпирически подтверждено, что малые выборки ($n = 10$) не позволяют достоверно определить вид распределения из-за высокого уровня статистического шума. Надежная аппроксимация теоретической кривой эмпирическими данными достигается только на больших объемах ($n = 1000$).
2. Важность группировки данных: Оптимальное количество интервалов (бинов) гистограммы динамически зависит от размера выборки. Правильная группировка не дает графику превратиться в бесполезный шум при малом количестве данных и позволяет сохранить детализацию формы при большом.
3. Специфика законов распределения: Визуальный анализ успешно проявил ключевые теоретические особенности случайных величин (острый пик Лапласа, прямоугольность равномерного, «тяжелые хвосты» и частые выбросы Коши), которые становятся очевидными только при достаточном количестве испытаний.

Список литературы

Электронные ресурсы:

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%201