Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №2:

«Характеристики положения и рассеяния»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи 3
Теоретическая часть 3
Реализация 6
Результаты 6
Обсуждение 8
Выводы 9
Список литературы 9
Приложение 9

Постановка задачи

Целью данной лабораторной работы является исследование точечных оценок характеристик положения и рассеяния случайных величин, а также проверка их состоятельности и робастности (устойчивости к выбросам). Основной задачей является эмпирическое сравнение пяти различных статистических оценок: выборочного среднего, выборочной медианы, полусуммы экстремальных элементов, полусуммы квартилей и усеченного среднего (с параметром отсечения 10%). Исследование проводится на базе пяти распределений (нормальное, Коши, Лапласа, Пуассона и равномерное) для выборок различных объемов: 10, 100 и 1000 элементов.

Для получения объективных характеристик исследуемых оценок необходимо применить метод статистического моделирования (метод Монте-Карло). Требуется повторить процедуру генерации выборок и вычисления всех пяти оценок 1000 раз для каждой комбинации распределения и объема выборки. На основе полученного массива данных (по 1000 значений для каждой оценки) необходимо вычислить эмпирическое математическое ожидание $E(z)$ и дисперсию $D(z)$.

Анализ полученных значений $E(z)$ и $D(z)$ позволит решить главные задачи исследования: во-первых, проверить сходимость выборочных характеристик к теоретическим значениям при увеличении объема выборки (стремление $D(z)$ к нулю); во-вторых, наглядно продемонстрировать проблему неустойчивости классического выборочного среднего к аномальным выбросам (что ярко проявляется на примере распределения Коши) и обосновать необходимость применения альтернативных, робастных методов оценки истинного центра распределения. Оформление результатов требует соблюдения правил округления: значение оценки приводится в виде $E \pm \sqrt{D}$, где для дисперсии оставляется одна значащая цифра, а точность математического ожидания согласуется с порядком погрешности.

Теоретическая часть

В математической статистике для нахождения истинного центра распределения случайной величины по имеющимся эмпирическим данным применяются различные точечные оценки, называемые характеристиками положения. Самой известной из них является выборочное среднее $\overline{x}$, вычисляемое как классическое среднее арифметическое всех элементов выборки. Второй базовой характеристикой выступает выборочная медиана med - центральное значение в упорядоченном по возрастанию массиве данных (вариационном ряду), которое делит выборку на две равные половины.

Помимо базовых оценок, в работе исследуются характеристики, вычисляемые на основе конкретных порядковых статистик. Так, полусумма экстремальных элементов находит центр исключительно по границам выборки:

$$z_R = \frac{x_{min} + x_{max}}{2}$$

Для оценки центральной части данных без учета их краев применяется полусумма квартилей, опирающаяся на 25-й ($z_{\frac{1}{4}}$) и 75-й ($z_{\frac{3}{4}}$) перцентили:

$$z_Q = \frac{z_{\frac{1}{4}} + z_{\frac{3}{4}}}{2}$$

Еще одним подходом является вычисление усеченного среднего z_{tr} При его нахождении вариационный ряд искусственно усекается: с обеих сторон отбрасывается заданный процент крайних значений (в нашей задаче — по 10% самых больших и самых малых элементов), после чего для оставшейся центральной части высчитывается обычное среднее арифметическое.

Для оценки точности и стабильности описанных характеристик применяется метод статистического моделирования (Монте-Карло). Любая характеристика положения z сама по себе является случайной величиной, зависящей от конкретной выборки. Многократно повторяя эксперимент (1000 раз), мы получаем массив значений оценки, для которого находим эмпирическое математическое ожидание $E(z)$ и эмпирическую дисперсию $D(z)$. В программной реализации расчет дисперсии характеристик положения осуществляется по формуле:

$$D(z) = \overline{z^2} - \overline{z}^2$$

где $\overline{z^2}$ - среднее арифметическое квадратов полученных оценок, а $\overline{z}^2$- квадрат их математического ожидания. Значение дисперсии по формуле выше является мерой рассеяния: чем оно ближе к нулю, тем точнее оценка сходится к истинному центру распределения.

Важнейшим теоретическим концептом данной работы выступает робастность — устойчивость статистической оценки к наличию в выборке грубых ошибок или аномальных выбросов. Выборочное среднее арифметическое является крайне неробастной оценкой: появление даже одного выброса (что является нормой для распределений с «тяжелыми хвостами», таких как распределение Коши) способно увести значение $\overline{x}$ бесконечно далеко от реального центра. Напротив, медиана, усеченное среднее и полусумма квартилей обладают высокой робастностью, так как математически игнорируют аномалии на краях распределения. Анализ значений $D(z)$ позволяет наглядно обосновать границы применимости каждой из характеристик.

Ниже приведены аналитические выражения для плотностей (и вероятностей) пяти исследуемых распределений с учетом заданных параметров, для которых будем искать выборочное среднее, медиану, полусумму экстремальных элементов, полусумму квартилей, усеченное среднее.

1. Нормальное распределение

   Стандартное нормальное распределение $N(0,1)$ характеризуется параметрами $\mu = 0$ (сдвиг) и $\sigma = 1$ (масштаб). Плотность вероятности описывается формулой Гаусса:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

2. Распределение Коши

   Распределение Коши $C(0,1)$ с параметрами сдвига $x_0 = 0$ и масштаба $\gamma = 1$. Это распределение известно своими «тяжелыми хвостами», из-за чего у него не определены математическое ожидание и дисперсия. Плотность имеет вид:

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

3. Распределение Лапласа

   Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$ с коэффициентами масштаба $b = \frac{1}{\sqrt{2}}$ и сдвигом $\mu = 0$. Его график напоминает два экспоненциальных спада, соединенных в острой вершине. Формула плотности:

$$f(x) = \frac{\sqrt{2}}{2} e^{-\sqrt{2}|x|}$$

4. Распределение Пуассона

   Это единственное дискретное распределение в работе. Случайная величина принимает только целые неотрицательные значения k. Для параметра $\lambda = 10$ вероятность выпадения числа k вычисляется как:

$$P(X = k) = \frac{10^k}{k!} e^{-10}$$

5. Равномерное распределение

   Непрерывное равномерное распределение $U(a, b)$ на отрезке $\left[-\sqrt{3}, \sqrt{3}\right]$. Длина интервала составляет $2\sqrt{3}$. Плотность вероятности постоянна внутри интервала и равна нулю вне его:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, x \in \left[-\sqrt{3}, \sqrt{3}\right] \\ 0, x \notin \left[-\sqrt{3}, \sqrt{3}\right] \end{cases}$$

Реализация

Разработка выполнена на языке Python с применением библиотек `numpy`, `scipy.stats` и `pandas`. Для обеспечения полной воспроизводимости результатов моделирования в начале скрипта фиксируется зерно генератора псевдослучайных чисел (seed). Оптимизация производительности достигнута за счет использования векторизованных матричных вычислений вместо медленных поэлементных циклов: метод генерации создает сразу двумерный массив размером 1000 строк (количество повторений эксперимента) на n столбцов (объем выборки).

Вычисление характеристик положения производится по строкам сгенерированной матрицы. Для этого используются высокопроизводительные функции библиотеки `numpy`: `mean` для выборочного среднего, `median` для медианы, а также `min`, `max` и `percentile` (с параметрами 25 и 75) для нахождения полусуммы экстремумов и полусуммы квартилей соответственно. Вычисление усеченного среднего реализовано через специализированную функцию `trim_mean` из модуля `scipy.stats`, которая автоматически отсекает заданную долю (по 10%) наименьших и наибольших элементов в каждой выборке.

После формирования массивов, содержащих по 1000 значений для каждой из пяти точечных оценок, скрипт вычисляет их эмпирическое математическое ожидание и дисперсию. Для структурирования и наглядного представления итоговых данных применяется библиотека `pandas`, которая автоматически сводит полученные значения $E(z)$ и $D(z)$ в отформатированные таблицы, удобные для переноса в отчет и последующего анализа.

Результаты

Ниже представлены результаты подсчёта характеристик, с указанием погрешно стей и теоретических значений.

```
==================================================================
Распределение: Нормальное N(0,1)
==================================================================
                        Оценка (n=10) Оценка (n=100) Оценка (n=1000)
Среднее (mean)             -0.0 ± 0.3      0.0 ± 0.1    -0.00 ± 0.03
Медиана (med)              -0.0 ± 0.4      0.0 ± 0.1    -0.00 ± 0.04
Полусумма экстр. (Z_R)     -0.0 ± 0.4      0.0 ± 0.3      -0.0 ± 0.3
Полусумма кварт. (Z_Q)     -0.0 ± 0.3      0.0 ± 0.1    -0.00 ± 0.03
Усеченное среднее (Z_tr)   -0.0 ± 0.3      0.0 ± 0.1    -0.00 ± 0.03
```

Рис. 1: Нормальное распределение

```
==================================================================
Распределение: Коши C(0,1)
==================================================================
                          Оценка (n=10) Оценка (n=100) Оценка (n=1000)
Среднее (mean)                  0 ± 55       -7 ± 269          0 ± 23
Медиана (med)                -0.0 ± 0.6     -0.0 ± 0.2    -0.00 ± 0.05
Полусумма экстр. (Z_R)          2 ± 274   -371 ± 13412      87 ± 11130
Полусумма кварт. (Z_Q)       -0.0 ± 1.0     -0.0 ± 0.2     0.00 ± 0.07
Усеченное среднее (Z_tr)         -0 ± 1     -0.0 ± 0.2     0.00 ± 0.07
```

Рис 2. Распределение Коши

```
==================================================================
Распределение: Лапласа L(0,1/√2)
==================================================================
                          Оценка (n=10) Оценка (n=100) Оценка (n=1000)
Среднее (mean)                0.0 ± 0.3   -0.00 ± 0.10     0.00 ± 0.03
Медиана (med)                 0.0 ± 0.3   -0.00 ± 0.08     0.00 ± 0.02
Полусумма экстр. (Z_R)        0.0 ± 0.6      0.0 ± 0.6       0.0 ± 0.6
Полусумма кварт. (Z_Q)        0.0 ± 0.3   -0.00 ± 0.10    -0.00 ± 0.03
Усеченное среднее (Z_tr)      0.0 ± 0.3   -0.00 ± 0.09    -0.00 ± 0.03
```

Рис 3. Распределение Лапласа

```
==================================================================
Распределение: Пуассона P(10)
==================================================================
                          Оценка (n=10) Оценка (n=100) Оценка (n=1000)
Среднее (mean)                 10 ± 1     10.0 ± 0.3    10.00 ± 0.10
Медиана (med)                  10 ± 1      9.9 ± 0.4    10.00 ± 0.05
Полусумма экстр. (Z_R)         10 ± 1     10.9 ± 1.0      11.7 ± 0.8
Полусумма кварт. (Z_Q)         10 ± 1      9.9 ± 0.4     9.99 ± 0.05
Усеченное среднее (Z_tr)       10 ± 1      9.9 ± 0.3       9.9 ± 0.1
```

Рис 4. Распределение Пуассона

```
==================================================================
Распределение: Равномерное U(-√3, √3)
==================================================================
                          Оценка (n=10) Оценка (n=100) Оценка (n=1000)
Среднее (mean)                0.0 ± 0.3    0.00 ± 0.10    -0.00 ± 0.03
Медиана (med)                 0.0 ± 0.5      0.0 ± 0.2    -0.00 ± 0.05
Полусумма экстр. (Z_R)       -0.0 ± 0.2    0.00 ± 0.02  -0.000 ± 0.002
Полусумма кварт. (Z_Q)        0.0 ± 0.4      0.0 ± 0.1    -0.00 ± 0.04
Усеченное среднее (Z_tr)      0.0 ± 0.4      0.0 ± 0.1    -0.00 ± 0.04
```

Рис 5. Равномерное распределение

Обсуждение

Анализ полученных расчетных таблиц позволяет наглядно проследить практическое проявление закона больших чисел. Для большинства распределений и характеристик наблюдается четкая тенденция: при увеличении объема выборки n от 10 к 100, а затем к 1000, среднеквадратичное отклонение оценок (погрешность) систематически уменьшается. Например, для выборочного среднего нормального распределения погрешность падает с ±0.3 до ±0.03. Это эмпирически подтверждает свойство состоятельности применяемых характеристик: по мере накопления данных они с высокой точностью сходятся к истинному теоретическому центру.

Самым показательным результатом эксперимента являются данные, полученные для распределения Коши, которые служат классической иллюстрацией понятия робастности. Классическое выборочное среднее показывает здесь свою полную несостоятельность: при росте n его погрешность не только не стремится к нулю, но и принимает гигантские, хаотичные значения (от ±55 при $n = 10$ до ±269 при $n = 100$). Аналогичный, но еще более масштабный провал демонстрирует оценка Z_R (погрешность достигает ±11130). Причина кроется в тяжелых хвостах распределения Коши, регулярно генерирующих экстремальные выбросы. В противовес им, робастные оценки - медиана и усеченное среднее (Z_{tr}) - полностью игнорируют эти аномалии, демонстрируя стабильное сужение доверительного интервала (до ±0.05 и ±0.07 соответственно) и точное нахождение центра.

Детальное сравнение показателей при большой выборке ($n = 1000$) доказывает, что универсальной «идеальной» оценки не существует; асимптотическая эффективность характеристики напрямую зависит от формы распределения:

1. Для нормального распределения наилучшей оценкой ожидаемо оказалось выборочное среднее, показавшее минимальное отклонение (±0.03).
2. Для распределения Лапласа ситуация меняется: из-за острой формы пика в центре распределения самой точной характеристикой стала медиана (±0.02), превзойдя среднее арифметическое.
3. Совершенно уникальная картина у равномерного распределения. Здесь абсолютным лидером стала полусумма экстремальных элементов Z_R. При $n = 1000$ её отклонение упало до околонулевых значений (±0.002). Это объясняется тем, что равномерное распределение строго ограничено краями отрезка и не имеет хвостов, поэтому минимум и максимум выборки идеально точно определяют ее границы.

Отдельно стоит отметить поведение оценок на асимметричном распределении Пуассона. Если выборочное среднее и медиана стабильно сходятся к математическому ожиданию 10, то полусумма экстремумов Z_R при $n = 1000$ дает результат 11.7±0.8. Это демонстрирует, что для несимметричных (или ограниченных только с одной стороны)

распределений неробастные оценки дают не просто большую погрешность, но и смещенный результат.

Подводя итог, можно выделить усеченное среднее (Z_{tr}) и полусумму квартилей (Z_Q) как наиболее безопасные, компромиссные характеристики. Они не всегда являются самыми эффективными (слегка уступая «лидерам» в конкретных распределениях), но при этом стабильно и надежно работают абсолютно на всех типах данных, гарантированно защищая результат от аномальных выбросов.

Выводы

1. Состоятельность оценок: Эмпирически подтверждено, что с увеличением объема выборки дисперсия характеристик положения стремительно уменьшается, что доказывает их сходимость к истинному центру распределения.
2. Проблема робастности: Выборочное среднее и полусумма экстремумов абсолютно неустойчивы к аномальным выбросам (что доказано на распределении Коши). Для данных с «тяжелыми хвостами» необходимо использовать робастные оценки: медиану, полусумму квартилей или усеченное среднее
3. Отсутствие универсальности**:** Самая точная (эффективная) оценка напрямую зависит от вида распределения: для нормального лучше всего работает выборочное среднее, для Лапласа — медиана, а для равномерного — полусумма крайних элементов

Список литературы

Электронные ресурсы:

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%202