Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №2:

«Характеристики положения и рассеяния»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи 3
Теоретическая часть 3
Реализация 6
Результаты 6
Обсуждение 7
Выводы 9
Список литературы 9
Приложение 9

Постановка задачи

Целью данной лабораторной работы является исследование точечных оценок характеристик положения и рассеяния случайных величин, а также проверка их состоятельности и робастности (устойчивости к выбросам). Основной задачей является эмпирическое сравнение пяти различных статистических оценок: выборочного среднего, выборочной медианы, полусуммы экстремальных элементов, полусуммы квартилей и усеченного среднего (с параметром отсечения 10%). Исследование проводится на базе пяти распределений (нормальное, Коши, Лапласа, Пуассона и равномерное) для выборок различных объемов: 10, 100 и 1000 элементов.

Для получения объективных характеристик исследуемых оценок необходимо применить метод статистического моделирования (метод Монте-Карло). Требуется повторить процедуру генерации выборок и вычисления всех пяти оценок 1000 раз для каждой комбинации распределения и объема выборки. На основе полученного массива данных (по 1000 значений для каждой оценки) необходимо вычислить эмпирическое математическое ожидание $E(z)$ и дисперсию $D(z)$.

Анализ полученных значений $E(z)$ и $D(z)$ позволит решить главные задачи исследования: во-первых, проверить сходимость выборочных характеристик к теоретическим значениям при увеличении объема выборки (стремление $D(z)$ к нулю); во-вторых, наглядно продемонстрировать проблему неустойчивости классического выборочного среднего к аномальным выбросам (что ярко проявляется на примере распределения Коши) и обосновать необходимость применения альтернативных, робастных методов оценки истинного центра распределения. Оформление результатов требует соблюдения правил округления: значение оценки приводится в виде $E \pm D$, где для дисперсии оставляется одна значащая цифра, а точность математического ожидания согласуется с порядком погрешности.

Теоретическая часть

В математической статистике для нахождения истинного центра распределения случайной величины по имеющимся эмпирическим данным применяются различные точечные оценки, называемые характеристиками положения. Самой известной из них является выборочное среднее $\overline{x}$, вычисляемое как классическое среднее арифметическое всех элементов выборки. Второй базовой характеристикой выступает выборочная медиана med - центральное значение в упорядоченном по возрастанию массиве данных (вариационном ряду), которое делит выборку на две равные половины.

Помимо базовых оценок, в работе исследуются характеристики, вычисляемые на основе конкретных порядковых статистик. Так, полусумма экстремальных элементов находит центр исключительно по границам выборки:

$$z_R = \frac{x_{min} + x_{max}}{2}$$

Для оценки центральной части данных без учета их краев применяется полусумма квартилей, опирающаяся на 25-й ($z_{\frac{1}{4}}$) и 75-й ($z_{\frac{3}{4}}$) перцентили:

$$z_Q = \frac{z_{\frac{1}{4}} + z_{\frac{3}{4}}}{2}$$

Еще одним подходом является вычисление усеченного среднего z_{tr} При его нахождении вариационный ряд искусственно усекается: с обеих сторон отбрасывается заданный процент крайних значений (в нашей задаче — по 10% самых больших и самых малых элементов), после чего для оставшейся центральной части высчитывается обычное среднее арифметическое.

Для оценки точности и стабильности описанных характеристик применяется метод статистического моделирования (Монте-Карло). Любая характеристика положения z сама по себе является случайной величиной, зависящей от конкретной выборки. Многократно повторяя эксперимент (1000 раз), мы получаем массив значений оценки, для которого находим эмпирическое математическое ожидание $E(z)$ и эмпирическую дисперсию $D(z)$. В программной реализации расчет дисперсии характеристик положения осуществляется по формуле:

$$D(z) = \overline{z^2} - \overline{z}^2$$

где $\overline{z^2}$ - среднее арифметическое квадратов полученных оценок, а $\overline{z}^2$- квадрат их математического ожидания. Значение дисперсии по формуле выше является мерой рассеяния: чем оно ближе к нулю, тем точнее оценка сходится к истинному центру распределения.

Важнейшим теоретическим концептом данной работы выступает робастность — устойчивость статистической оценки к наличию в выборке грубых ошибок или аномальных выбросов. Выборочное среднее арифметическое является крайне неробастной оценкой: появление даже одного выброса (что является нормой для распределений с «тяжелыми хвостами», таких как распределение Коши) способно увести значение $\overline{x}$ бесконечно далеко от реального центра. Напротив, медиана, усеченное среднее и полусумма квартилей обладают высокой робастностью, так как математически игнорируют аномалии на краях распределения. Анализ значений $D(z)$ позволяет наглядно обосновать границы применимости каждой из характеристик.

Ниже приведены аналитические выражения для плотностей (и вероятностей) пяти исследуемых распределений с учетом заданных параметров, для которых будем искать выборочное среднее, медиану, полусумму экстремальных элементов, полусумму квартилей, усеченное среднее.

1. Нормальное распределение

   Стандартное нормальное распределение $N(0,1)$ характеризуется параметрами $\mu = 0$ (сдвиг) и $\sigma = 1$ (масштаб). Плотность вероятности описывается формулой Гаусса:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

2. Распределение Коши

   Распределение Коши $C(0,1)$ с параметрами сдвига $x_0 = 0$ и масштаба $\gamma = 1$. Это распределение известно своими «тяжелыми хвостами», из-за чего у него не определены математическое ожидание и дисперсия. Плотность имеет вид:

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

3. Распределение Лапласа

   Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$ с коэффициентами масштаба $b = \frac{1}{\sqrt{2}}$ и сдвигом $\mu = 0$. Его график напоминает два экспоненциальных спада, соединенных в острой вершине. Формула плотности:

$$f(x) = \frac{\sqrt{2}}{2} e^{-\sqrt{2}|x|}$$

4. Распределение Пуассона

   Это единственное дискретное распределение в работе. Случайная величина принимает только целые неотрицательные значения k. Для параметра $\lambda = 10$ вероятность выпадения числа k вычисляется как:

$$P(X = k) = \frac{10^k}{k!} e^{-10}$$

5. Равномерное распределение

   Непрерывное равномерное распределение $U(a, b)$ на отрезке $\left[-\sqrt{3}, \sqrt{3}\right]$. Длина интервала составляет $2\sqrt{3}$. Плотность вероятности постоянна внутри интервала и равна нулю вне его:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, x \in \left[-\sqrt{3}, \sqrt{3}\right] \\ 0, x \notin \left[-\sqrt{3}, \sqrt{3}\right] \end{cases}$$

Реализация

Разработка выполнена на языке Python с применением библиотек `numpy`, `scipy.stats` и `pandas`. Для обеспечения полной воспроизводимости результатов моделирования в начале скрипта фиксируется зерно генератора псевдослучайных чисел (seed). Оптимизация производительности достигнута за счет использования векторизованных матричных вычислений вместо медленных поэлементных циклов: метод генерации создает сразу двумерный массив размером 1000 строк (количество повторений эксперимента) на n столбцов (объем выборки).

Вычисление характеристик положения производится по строкам сгенерированной матрицы. Для этого используются высокопроизводительные функции библиотеки `numpy`: `mean` для выборочного среднего, `median` для медианы, а также `min`, `max` и `percentile` (с параметрами 25 и 75) для нахождения полусуммы экстремумов и полусуммы квартилей соответственно. Вычисление усеченного среднего реализовано через специализированную функцию `trim_mean` из модуля `scipy.stats`, которая автоматически отсекает заданную долю (по 10%) наименьших и наибольших элементов в каждой выборке.

После формирования массивов, содержащих по 1000 значений для каждой из пяти точечных оценок, скрипт вычисляет их эмпирическое математическое ожидание и дисперсию. Для структурирования и наглядного представления итоговых данных применяется библиотека `pandas`, которая автоматически сводит полученные значения $E(z)$ и $D(z)$ в отформатированные таблицы, удобные для переноса в отчет и последующего анализа.

Результаты

Ниже представлены результаты подсчёта характеристик, с указанием погрешно стей и теоретических значений.

```
======================================================================
Распределение: Нормальное N(0,1)
======================================================================
                          E(z), n=10  D(z), n=10  E(z), n=100  D(z), n=100  E(z), n=1000  D(z), n=1000
Среднее (mean)             -0.002136    0.098500     0.002312     0.010748     -0.001718      0.001030
Медиана (med)              -0.009032    0.133654     0.003452     0.014918     -0.000953      0.001593
Полусумма экстр. (Z_R)     -0.001693    0.184695     0.001012     0.092775     -0.005589      0.062965
Полусумма кварт. (Z_Q)     -0.000951    0.112995     0.002373     0.013146     -0.002350      0.001170
Усеченное среднее (Z_tr)   -0.002247    0.102487     0.002511     0.011226     -0.001621      0.001066
```

Рис. 1: Нормальное распределение

```
=====================================================================
Распределение: Коши C(0,1)
=====================================================================
                        E(z), n=10    D(z), n=10  E(z), n=100   D(z), n=100  E(z), n=1000  D(z), n=1000
Среднее (mean)            0.471570   3013.627087    -7.393470  7.211300e+04      0.188113  5.267733e+02
Медиана (med)            -0.008025      0.369226    -0.005088  2.375700e-02     -0.000712  2.543000e-03
Полусумма экстр. (Z_R)    2.398404  75124.412956  -371.118434  1.798852e+08     86.874969  1.238699e+08
Полусумма кварт. (Z_Q)   -0.047778      0.999302    -0.010522  5.530100e-02      0.001023  4.972000e-03
Усеченное среднее (Z_tr) -0.010138      1.324560    -0.013152  5.499900e-02      0.000351  4.628000e-03
```

Рис 2. Распределение Коши

```
=====================================================================
Распределение: Лапласа L(0,1/√2)
=====================================================================
                        E(z), n=10  D(z), n=10  E(z), n=100  D(z), n=100  E(z), n=1000  D(z), n=1000
Среднее (mean)            0.018226    0.103057    -0.000954     0.009819      0.000042      0.000990
Медиана (med)             0.014355    0.076346    -0.002861     0.006078      0.000188      0.000506
Полусумма экстр. (Z_R)    0.043698    0.405983     0.020620     0.387426      0.001906      0.375834
Полусумма кварт. (Z_Q)    0.005337    0.091676    -0.002216     0.009947     -0.000184      0.001003
Усеченное среднее (Z_tr)  0.011858    0.082709    -0.002253     0.007565     -0.000049      0.000745
```

Рис 3. Распределение Лапласа

```
=====================================================================
Распределение: Пуассона P(10)
=====================================================================
                        E(z), n=10  D(z), n=10  E(z), n=100  D(z), n=100  E(z), n=1000  D(z), n=1000
Среднее (mean)           10.040100    1.085882    10.022640     0.093627     10.000533      0.009802
Медиана (med)             9.911000    1.565579     9.871000     0.186359      9.997500      0.002244
Полусумма экстр. (Z_R)   10.286500    1.945668    10.923500     0.940398     11.653000      0.690091
Полусумма кварт. (Z_Q)    9.985125    1.234451     9.932750     0.131040      9.994625      0.002830
Усеченное среднее (Z_tr)  9.978500    1.152194     9.934238     0.099230      9.905706      0.010458
```

Рис 4. Распределение Пуассона

```
=====================================================================
Распределение: Равномерное U(-√3, √3)
=====================================================================
                        E(z), n=10  D(z), n=10  E(z), n=100  D(z), n=100  E(z), n=1000  D(z), n=1000
Среднее (mean)            0.000108    0.099948     0.001803     0.009643     -0.000792      0.000957
Медиана (med)             0.007589    0.226996     0.000916     0.028316     -0.001447      0.002813
Полусумма экстр. (Z_R)   -0.002337    0.047049     0.000875     0.000567     -0.000059      0.000006
Полусумма кварт. (Z_Q)    0.000865    0.138729     0.002465     0.014255     -0.000386      0.001388
Усеченное среднее (Z_tr)  0.000719    0.130222     0.001945     0.013463     -0.000758      0.001345
```

Рис 5. Равномерное распределение

Обсуждение

Анализ полученных расчетных таблиц позволяет наглядно проследить практическое проявление закона больших чисел. Для большинства распределений и характеристик наблюдается четкая тенденция: при увеличении объема выборки n от 10 к 100, а затем к 1000, дисперсия $D(z)$ уменьшается примерно на порядок на каждом шаге. Это подтверждает состоятельность применяемых точечных оценок — по мере накопления данных их значения стабилизируются и сходятся к истинному теоретическому центру распределения.

Самым показательным и концептуально важным результатом данного эксперимента являются данные, полученные для распределения Коши. На его примере блестяще демонстрируется понятие робастности. Классическое выборочное среднее показывает здесь свою полную несостоятельность: его математическое ожидание хаотично колеблется, а дисперсия не только не стремится к нулю с ростом выборки, но и принимает астрономические значения (от $3 \cdot 10^3$ до $5 \cdot 10^2$). Аналогичный провал показывает и оценка Z_R. Причина кроется в «тяжелых хвостах» распределения Коши, генерирующих экстремальные выбросы, к которым эти две характеристики максимально уязвимы. В противовес им, медиана и усеченное среднее (Z_{tr}) успешно игнорируют аномалии на краях выборки, демонстрируя стабильное падение дисперсии ($10^{-1} \to 10^{-2} \to 10^{-3}$) и точное нахождение центрального значения.

Детальное сравнение показателей дисперсии при большой выборке ($n = 1000$) доказывает, что универсальной идеальной оценки не существует; эффективность характеристики напрямую зависит от природы распределения случайной величины. Так, для стандартного нормального распределения наилучшей (наиболее эффективной) оценкой ожидаемо оказалось выборочное среднее — оно показало наименьшую дисперсию (0.001030). Однако для распределения Лапласа ситуация меняется: из-за острой формы пика в центре распределения самой точной характеристикой стала медиана ($D \approx 0.000506$), превзойдя среднее арифметическое.

Совершенно уникальная картина наблюдается в таблице равномерного распределения. Здесь безусловным лидером с огромным отрывом стала полусумма экстремальных элементов Z_R. При $n = 1000$ ее дисперсия упала до околонулевых значений (0.000006). Это объясняется тем, что равномерное распределение строго ограничено краями отрезка и не имеет хвостов, поэтому минимум и максимум выборки идеально точно определяют ее границы и, следовательно, центр.

Подводя итог анализу всех таблиц, можно выделить усеченное среднее (Z_{tr}) и полусумму квартилей (Z_Q) как наиболее безопасные, компромиссные характеристики. Они не всегда являются самыми эффективными (иногда немного уступая среднему или медиане), но при этом стабильно и надежно работают абсолютно на всех исследованных распределениях, включая распределение Коши.

Выводы

1. Состоятельность оценок: Эмпирически подтверждено, что с увеличением объема выборки дисперсия характеристик положения стремительно уменьшается, что доказывает их сходимость к истинному центру распределения.
2. Проблема робастности: Выборочное среднее и полусумма экстремумов абсолютно неустойчивы к аномальным выбросам (что доказано на распределении Коши). Для данных с «тяжелыми хвостами» необходимо использовать робастные оценки: медиану, полусумму квартилей или усеченное среднее
3. Отсутствие универсальности**:** Самая точная (эффективная) оценка напрямую зависит от вида распределения: для нормального лучше всего работает выборочное среднее, для Лапласа — медиана, а для равномерного — полусумма крайних элементов

Список литературы

Электронные ресурсы:

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%202