Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №3:

«Боксплот Тьюки и анализ выбросов»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи 3
Теоретическая часть 3
Реализация 5
Результаты 6
Обсуждение 7
Выводы 8
Список литературы 9
Приложение 9

Постановка задачи

Целью данной лабораторной работы является освоение методов визуального разведочного анализа данных и количественной оценки аномальных значений (выбросов) с использованием графического инструмента «боксплот Тьюки». Основной задачей исследования является анализ влияния различных законов распределения и объемов выборки на форму ящика, длину усов и, главное, на вероятность появления выбросов за пределами нормального размаха данных. Исследование проводится для пяти непрерывных и дискретных распределений: нормального, Коши, Лапласа, Пуассона и равномерного.

Для достижения цели работа разделена на две части: качественную (визуальную) и количественную (аналитическую). В первой части необходимо сгенерировать выборки объемом $n = 20$ и $n = 100$ для каждого из исследуемых распределений. На основе полученных данных требуется построить совмещенные графики (боксплоты), которые позволят наглядно сопоставить медианы, межквартильный размах и наличие экстремальных значений для разных случайных величин на одной координатной плоскости.

Вторая часть работы предполагает экспериментальное определение доли выбросов методом статистического моделирования (Монте-Карло). Согласно алгоритму Джона Тьюки, выбросом считается любое значение, выходящее за границы интервала $[Q_1 - 1.5 \cdot IQR; Q_3 + 1.5 \cdot IQR]$. Для обеспечения статистической достоверности требуется сгенерировать 1000 независимых выборок заданного объема для каждого распределения, программно рассчитать границы Тьюки, подсчитать количество значений, выходящих за эти пределы, и вычислить среднюю экспериментальную долю выбросов. Полученные результаты необходимо свести в таблицу для последующего анализа влияния тяжести «хвостов» распределения на количество аномалий.

Теоретическая часть

Боксплот, предложенный математиком Джоном Тьюки, является одним из основных инструментов разведочного анализа данных. Этот график позволяет компактно визуализировать одномерное распределение на основе его порядковых статистик. Центральным элементом графика является прямоугольник, нижняя граница которого соответствует первому квартилю (Q_1, 25-й перцентиль), а верхняя — третьему квартилю (Q_3, 75-й перцентиль). Внутри ящика проводится линия, обозначающая выборочную медиану. Высота этого прямоугольника называется межквартильным размахом (IQR) и содержит ровно 50% центральных элементов выборки:

$$IQR = Q_3 - Q_1$$

От верхней и нижней граней ящика отходят линии, называемые «усами». В классическом подходе Тьюки усы строятся не до абсолютного минимума и максимума выборки, а до крайних значений, которые укладываются в допустимый интервал нормального рассеяния данных. Границы этого интервала вычисляются с использованием коэффициента 1.5:

$$X_{min}^{bound} = Q_1 - 1.5 \cdot IQR$$

$$X_{max}^{bound} = Q_3 + 1.5 \cdot IQR$$

Ключевым понятием в данном методе является выброс (или аномальное значение). Выбросом считается любой элемент выборки, который строго меньше нижней границы, вычисленной по формуле X_{min}^{bound}, или строго больше верхней границы по формуле X_{max}^{bound}. На графике такие элементы не покрываются усами, а отображаются в виде отдельных точек (маркеров). Доля выбросов в выборке рассчитывается как отношение количества аномальных точек к общему объему выборки n.

Теоретическая вероятность появления выбросов напрямую зависит от формы плотности распределения случайной величины. Для нормального закона распределения интервал Тьюки охватывает примерно 2.7 стандартных отклонения (2.7σ), поэтому выбросы появляются редко (теоретическая вероятность около 0.7%). Однако для распределений с так называемыми «тяжелыми хвостами» (Коши, Лапласа) вероятность генерации значений, бесконечно удаленных от центра, математически высока. Следовательно, для таких распределений ожидается фиксация значительно большей доли выбросов. Напротив, распределения с жестко ограниченным диапазоном значений (например, равномерное) при достаточных объемах выборок исключают появление выбросов в принципе, так как весь размах их данных укладывается внутрь расчетных границ Тьюки.

Ниже приведены аналитические выражения для плотностей (и вероятностей) пяти исследуемых распределений с учетом заданных параметров, для которых будем рассчитывать боксплоты и выбросы.

1. Нормальное распределение
   Стандартное нормальное распределение $N(0,1)$ характеризуется параметрами $\mu = 0$ (сдвиг) и $\sigma = 1$ (масштаб). Плотность вероятности описывается формулой Гаусса:
   $$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$
2. Распределение Коши
   Распределение Коши $C(0,1)$ с параметрами сдвига $x_0 = 0$ и масштаба $\gamma = 1$. Это распределение известно своими «тяжелыми хвостами», из-за чего у него не определены математическое ожидание и дисперсия. Плотность имеет вид:

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

3. Распределение Лапласа

   Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$ с коэффициентами масштаба $b = \frac{1}{\sqrt{2}}$ и сдвигом $\mu = 0$. Его график напоминает два экспоненциальных спада, соединенных в острой вершине. Формула плотности:

$$f(x) = \frac{\sqrt{2}}{2} e^{-\sqrt{2}|x|}$$

4. Распределение Пуассона

   Это единственное дискретное распределение в работе. Случайная величина принимает только целые неотрицательные значения k. Для параметра $\lambda = 10$ вероятность выпадения числа k вычисляется как:

$$P(X = k) = \frac{10^k}{k!} e^{-10}$$

5. Равномерное распределение

   Непрерывное равномерное распределение $U(a, b)$ на отрезке $\left[-\sqrt{3}, \sqrt{3}\right]$. Длина интервала составляет $2\sqrt{3}$. Плотность вероятности постоянна внутри интервала и равна нулю вне его:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, x \in \left[-\sqrt{3}, \sqrt{3}\right] \\ 0, x \notin \left[-\sqrt{3}, \sqrt{3}\right] \end{cases}$$

Реализация

Разработка выполнена на языке Python с использованием библиотек `numpy` (для векторных вычислений), `scipy.stats` (для генерации распределений), `matplotlib` (для визуализации) и `pandas` (для формирования итоговой таблицы). Для гарантии воспроизводимости результатов в начале скрипта жестко фиксируется зерно генератора случайных чисел (seed).

В первой части программы графики строятся с помощью встроенной функции `plt.boxplot()`, которой передается параметр `whis=1.5` для строгого соответствия классическому алгоритму Тьюки. Ключевой технической особенностью блока визуализации является принудительное ограничение области отрисовки по оси Y (от -6 до 18). Это программное решение необходимо из-за специфики распределения Коши: без обрезки осей его экстремальные выбросы, уходящие в тысячные значения, масштабировали бы график так, что ящики остальных распределений сжались бы в одну неразличимую линию.

Во второй части программы реализован высокопроизводительный расчет доли выбросов методом Монте-Карло. Вместо использования медленных циклов генерация данных происходит матричным способом: создаются двумерные массивы размером 1000 строк (повторений) на n столбцов. Вычисление первого и третьего квартилей производится функцией `np.percentile` по строкам (`axis=1`). С помощью векторизованных арифметических операций рассчитывается межквартильный размах (IQR) и границы усов. Выбросы детектируются наложением логических масок: элементы матрицы проверяются на выход за пределы вычисленных границ. Применение функции `np.mean()` к полученному булевому массиву (True/False) позволяет за одну операцию вычислить итоговую среднюю долю выбросов. Результаты эксперимента форматируются и выводятся с помощью объекта `DataFrame` из библиотеки Pandas.

Результаты

Ниже представлены боксплоты и таблица долей выбросов.

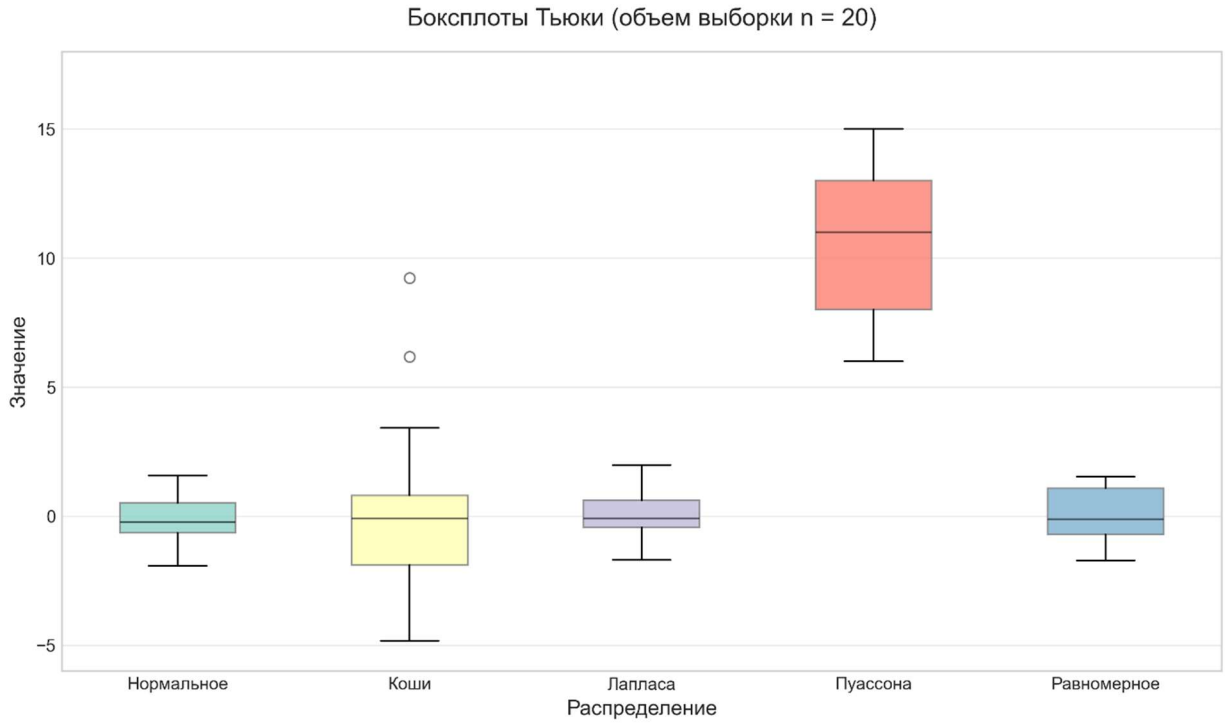

Рисунок 1 Боксплоты распределений для n = 20

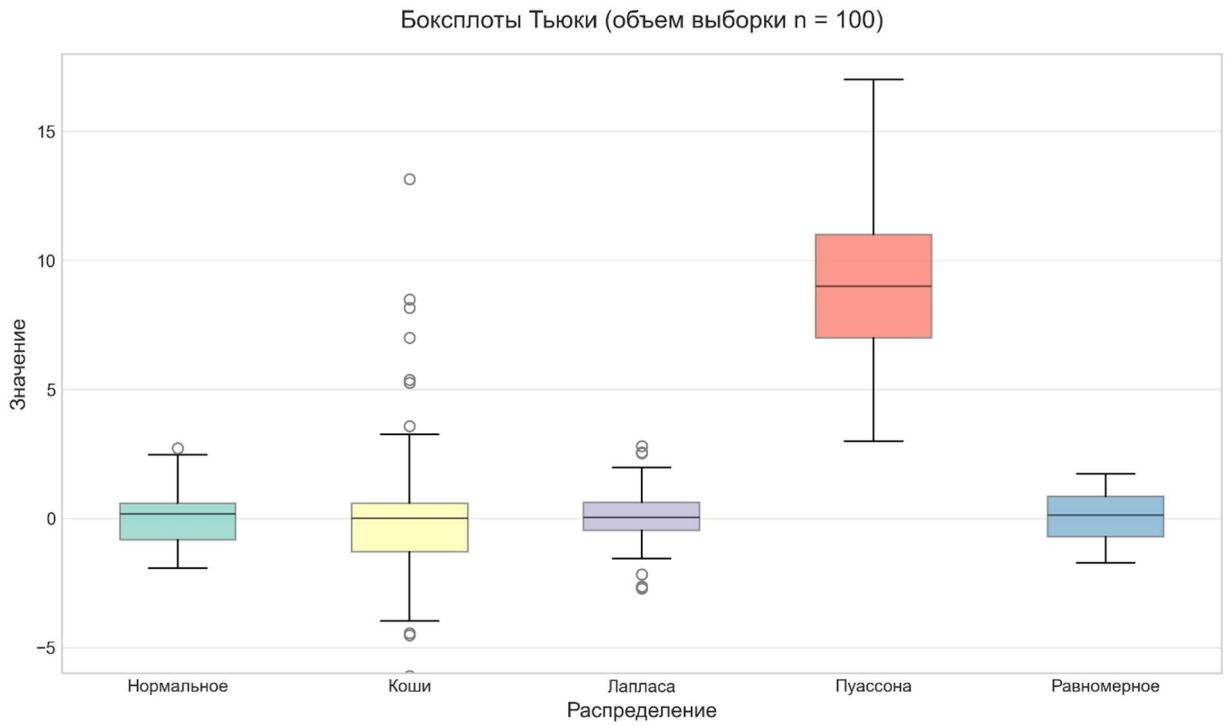

Рисунок 2 Боксплоты распределений для n = 100

Обсуждение

Анализ построенных графиков позволяет наглядно сопоставить форму и размах исследуемых распределений. Визуально легко считываются базовые характеристики: медиана (горизонтальная линия внутри прямоугольника) почти у всех непрерывных распределений находится вблизи нуля, что соответствует их теоретическому математическому ожиданию. Распределение Пуассона ($P = 10$) заметно выделяется на фоне остальных, так как его медиана и весь межквартильный размах смещены в область положительных значений вокруг десятки, что полностью согласуется с параметром $\lambda = 10$.

Особое внимание следует уделить поведению распределений за пределами «усов» графика, то есть генерации аномальных значений (выбросов). Ожидаемо, самым нестабильным оказалось распределение Коши. На обоих графиках (и при $n = 20$, и при $n = 100$) над и под его ящиком наблюдается большое количество точек-выбросов. Более того, чтобы эти графики вообще можно было рассмотреть в едином масштабе с другими, ось ординат пришлось принудительно обрезать, так как экстремумы Коши уходили далеко за пределы значений ± 100. Это является прямым визуальным доказательством наличия бесконечной дисперсии и тяжелых хвостов у данного распределения.

Распределение Лапласа, хотя и не генерирует таких радикальных аномалий, как Коши, все же демонстрирует склонность к выбросам. На графике для $n = 100$ хорошо видны точки за пределами усов как сверху, так и снизу. Это объясняется формой его плотности: график Лапласа имеет более острый пик в центре и спадает медленнее, чем колокол Гаусса, что повышает вероятность генерации значений на краях. Стандартное нормальное распределение ведет себя значительно "сдержаннее": при малой выборке ($n = 20$) выбросов может не быть вовсе, а при $n = 100$ появляются лишь единичные точки, что соответствует теоретической доле в ≈0.7%.

Уникальную картину демонстрирует равномерное распределение. На обоих графиках у него полностью отсутствуют выбросы в виде точек, а концы «усов» строго упираются в математические границы распределения ($\sqrt{-3}$ и $\sqrt{3}$). Такая форма боксплота логична: плотность равномерного распределения строго равна нулю за пределами своего интервала. Межквартильный размах (IQR) здесь достаточно широк, чтобы расчетные границы Тьюки ($Q_{1,3} \pm 1.5 \cdot IQR$) всегда оказывались шире фактического диапазона возможных значений случайной величины, что делает появление выбросов физически невозможным.

Сравнение графиков для разных объемов выборок ($n = 20$ и $n = 100$) показывает, что увеличение объема данных делает боксплот более симметричным и стабильным. При $n = 20$ медиана часто смещена относительно центра ящика, а усы могут иметь разную длину из-за случайных флуктуаций. При $n = 100$ ящики нормального, равномерного распределений и Лапласа становятся визуально симметричными, что свидетельствует о сходимости эмпирических данных к теоретическим параметрам генеральной совокупности.

Выводы

1. Эффективность инструмента: Боксплот Тьюки является компактным и информативным методом разведочного анализа, позволяющим быстро оценить центр распределения (медиану), разброс данных (межквартильный размах) и наличие аномалий на одном графике.
2. Зависимость от формы распределения**:** Доля детектируемых выбросов критически зависит от тяжести «хвостов» случайной величины: для Коши и Лапласа она максимальна, для нормального распределения минимальна, а для равномерного выбросы физически невозможны.
3. лияние объема выборки: При увеличении объема выборки (с $n = 20$ до $n = 100$) боксплоты становятся более симметричными и стабильными, а экспериментальная доля выбросов сходится к истинному теоретическому значению.

Список литературы

Электронные ресурсы:

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%203