

Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №4:

«Эмпирическая функция распределения и ядерные оценки плотности»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи	3
Теоретическая часть	3
Реализация	6
Результаты.....	7
Обсуждение	10
Выводы.....	12
Список литературы	12
Приложение	12

Постановка задачи

Целью данной лабораторной работы является исследование методов непараметрического оценивания законов распределения случайных величин на основе ограниченных эмпирических данных. Рассматривается два фундаментальных статистических инструмента: эмпирическая функция распределения (ЭФР), описывающая накопленную вероятность, и ядерная оценка плотности (KDE), представляющая собой математический алгоритм сглаживания вероятностных кривых.

Для проведения исследования используется метод компьютерного моделирования. В рамках работы генерируются независимые выборки трех объемов ($n = 20, 60, 100$) для пяти различных распределений: нормального, Коши, Лапласа, Пуассона и равномерного. На базе этих данных требуется визуализировать и сопоставить полученные эмпирические графики с их теоретическими математическими эталонами. Чтобы обеспечить наглядность и сфокусировать внимание на наиболее информативной центральной части распределений, область построения всех графиков строго ограничивается заданными отрезками: $[-4, 4]$ для непрерывных случайных величин и $[6, 14]$ для дискретного распределения Пуассона.

Основной аналитической задачей работы является изучение влияния объема выборки на качество статистической аппроксимации. Во-первых, необходимо проследить, как с ростом числа наблюдений ступенчатый график ЭФР приближается к истинной функции распределения, что на практике иллюстрирует фундаментальную теорему Гливенко — Кантелли. Во-вторых, требуется оценить эффективность ядерного сглаживания с использованием гауссова ядра в качестве альтернативы классическим гистограммам, изученным в первой лабораторной работе. Предстоит наглядно продемонстрировать, как применение алгоритма KDE решает проблему «ступенчатости», позволяя восстановить гладкую непрерывную функцию плотности, а также проанализировать уязвимость данного метода к ложным флуктуациям при малых объемах данных.

Теоретическая часть

В математической статистике для описания неизвестного закона распределения по имеющейся выборке широко применяются непараметрические методы оценивания. Первым и наиболее фундаментальным из них является эмпирическая функция распределения (ЭФР), обозначаемая как $F_n(x)$. Она представляет собой выборочный аналог истинной (теоретической) функции распределения $F(x)$. Построение ЭФР базируется на вариационном ряду выборки: это ступенчатая функция, которая совершает скачок величиной $\frac{1}{n}$ в каждой точке наблюдения X_i . Важнейшим математическим обоснованием использования ЭФР служит теорема Гливенко - Кантелли, которая гласит, что при

неограниченном увеличении объема выборки ($n \rightarrow \infty$) эмпирическая функция $F_n(x)$ сходится по вероятности к истинной функции распределения $F(x)$ равномерно на всей числовой оси.

Помимо интегральной оценки вероятности, не менее важной задачей является оценка плотности распределения. Классическим способом визуализации плотности служит гистограмма, однако она имеет существенный недостаток: график гистограммы является ступенчатой, разрывной функцией. Поскольку истинные функции плотности для непрерывных случайных величин являются гладкими, гистограммы дают приемлемую аппроксимацию только при очень больших объемах наблюдений. Для получения более естественной, гладкой кривой вероятности применяется ядерная оценка плотности (Kernel Density Estimation, KDE).

Суть метода ядерного сглаживания заключается в отказе от жесткой группировки данных по интервалам. Вместо этого в каждую точку наблюдения помещается гладкая, симметричная весовая функция — так называемое «ядро». Результирующая кривая плотности получается путем суммирования и усреднения всех этих функций. Аналитически ядерная оценка плотности $\hat{f}_h(x)$ вычисляется по формуле:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

где $K(u)$ — ядерная функция, а h — параметр сглаживания (или ширина окна). В рамках данной лабораторной работы применяется классическое гауссово ядро, задаваемое формулой плотности стандартного нормального распределения: $K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$

Физический смысл параметра h заключается в том, что он выступает в роли стандартного отклонения для каждой локальной гауссовой функции (ядра), помещаемой в точки наблюдения X_i . Чем больше значение h , тем шире и «расплывчатее» становится каждый локальный колокол, а итоговая кривая сглаживается. Напротив, при малом h локальные колокола становятся узкими, и график начинает описывать каждую отдельную точку выборки.

На практике параметр h редко задается вручную. В современных статистических пакетах для его автоматического вычисления по умолчанию применяется правило Скотта. Формула правила Скотта опирается на объем выборки n и выборочное стандартное отклонение $\hat{\sigma}$:

$$h \approx n^{-\frac{1}{5}} \cdot \hat{\sigma}$$

Таким образом, ширина окна h динамически подстраивается под разброс конкретных данных: алгоритм оценивает общую дисперсию выборки и пропорционально ей задает ширину сглаживающих ядер. Однако качество такой оценки критически зависит от отсутствия в выборке аномальных выбросов.

Качество ядерной оценки критически зависит от объема выборки и выбора параметра h . При малых объемах выборки ядерная оценка склонна к «переобучению»: алгоритм пытается описать каждую случайную флуктуацию данных, из-за чего на графике появляются ложные пики и волны. По мере роста числа наблюдений эти случайные всплески компенсируют друг друга, и кривая KDE плавно сходится к истинной теоретической плотности распределения. Стоит также отметить специфику применения KDE к дискретным случайным величинам (например, распределению Пуассона): поскольку ядро является непрерывной функцией, алгоритм формирует непрерывную огибающую кривую над дискретными точками, что является математической абстракцией, но визуально помогает оценить общую форму распределения.

Рассматривались следующие распределения:

1. Нормальное распределение

Стандартное нормальное распределение $N(0,1)$ характеризуется параметрами $\mu = 0$ (сдвиг) и $\sigma = 1$ (масштаб). Плотность вероятности описывается формулой Гаусса:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

2. Распределение Коши

Распределение Коши $C(0,1)$ с параметрами сдвига $x_0 = 0$ и масштаба $\gamma = 1$. Это распределение известно своими «тяжелыми хвостами», из-за чего у него не определены математическое ожидание и дисперсия. Плотность имеет вид:

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

3. Распределение Лапласа

Распределение Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$ с коэффициентами масштаба $b = \frac{1}{\sqrt{2}}$ и сдвигом $\mu = 0$. Его график напоминает два экспоненциальных спада, соединенных в острой вершине. Формула плотности:

$$f(x) = \frac{\sqrt{2}}{2} e^{-\sqrt{2}|x|}$$

4. Распределение Пуассона

Это единственное дискретное распределение в работе. Случайная величина принимает только целые неотрицательные значения k . Для параметра $\lambda = 10$ вероятность выпадения числа k вычисляется как:

$$P(X = k) = \frac{10^k}{k!} e^{-10}$$

5. Равномерное распределение

Непрерывное равномерное распределение $U(a, b)$ на отрезке $[-\sqrt{3}, \sqrt{3}]$. Длина интервала составляет $2\sqrt{3}$. Плотность вероятности постоянна внутри интервала и равна нулю вне его:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}, \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}, \sqrt{3}] \end{cases}$$

Реализация

Разработка выполнена на языке Python с применением библиотек `numpy`, `scipy.stats` и `matplotlib`. Для чистоты эксперимента выборки случайных величин генерируются однократно, что позволяет строить графики эмпирической функции распределения (ЭФР) и ядерной оценки плотности (KDE) на абсолютно идентичных данных.

Для построения ЭФР массив выборки предварительно сортируется по возрастанию. Накопленные вероятности рассчитываются как равномерный шаг от $\frac{1}{n}$ до 1. Визуализация ступенчатого графика реализована с помощью метода `plt.step` с параметром `where='post'`, что алгоритмически обеспечивает математически корректную отрисовку правосторонних разрывов («ступенек»). Чтобы график визуально доходил до краев координатной плоскости, массивы эмпирических данных программно дополняются заданными граничными точками интервала.

Ядерная оценка плотности вычисляется с помощью встроенного класса `gaussian_kde` из модуля `scipy.stats`. Данный метод использует гауссово ядро и автоматически рассчитывает оптимальный параметр сглаживания (ширину окна) на основе правила Скотта. Непрерывная кривая плотности вычисляется на равномерной сетке из 1000 точек. В строгом соответствии с заданием, область видимости графиков жестко ограничивается по оси абсцисс (отрезки $[-4, 4]$ и $[6, 14]$), а по оси ординат для графиков плотности устанавливается принудительная нижняя граница в нуле. Для демонстрации влияния ширины окна на качество аппроксимации (на примере распределения Коши) был написан дополнительный программный модуль. В нем стандартный множитель, рассчитанный по правилу Скотта (`kde.factor`), принудительно переопределялся с помощью встроенного метода `set_bandwidth`. Это позволило программно масштабировать параметр h в 0.1 и 2.5 раза, искусственно вызывая эффекты недосглаживания и пересглаживания для наглядного визуального анализа.

Результаты

Ниже представлены графики приближений (синие), их теоретические кривые (красные).




Рисунок 1: Приближение эмпирической функцией N




Рисунок 2: Приближение эмпирической функцией C




Рисунок 3: Приближение эмпирической функцией L

Poisson $P(10)$




Рисунок 4: Приближение эмпирической функцией P

Uniform $U(-\sqrt{3}, \sqrt{3})$




Рисунок 5: Приближение эмпирической функцией U

Normal $N(0, 1)$




Рисунок 6: Приближение ядерным сглаживанием N

Cauchy $C(0, 1)$




Рисунок 7: Приближение ядерным сглаживанием C

Laplace $L(0, 1/\sqrt{2})$




Рисунок 8: Приближение ядерным сглаживанием L

Poisson $P(10)$




Рисунок 9: Приближение ядерным сглаживанием P




Рисунок 10: Приближение ядерным сглаживанием U




Рисунок 11: Приближение ядерным сглаживанием N для h равным $2.5h$, $1h$, $0.1h$

Обсуждение

Анализ построенных графиков позволяет детально изучить поведение непараметрических оценок и их зависимость от объема эмпирических данных (n), а также выявить специфические ограничения метода ядерного сглаживания.

1. Эмпирическая функция распределения

На графиках функций распределения (CDF) для всех пяти случайных величин наглядно демонстрируется практическое выполнение теоремы Гливенко - Кантелли. При малом объеме выборки ($n = 20$) эмпирическая кривая имеет широкие «ступени» и лишь грубо повторяет контур теоретической красной линии, демонстрируя значительные локальные отклонения. По мере увеличения объема выборки до $n = 60$ и $n = 100$ высота и ширина ступеней пропорционально уменьшаются (так как шаг равен $\frac{1}{n}$), и синяя ломаная линия начинает плотно и равномерно прилегать к истинной функции распределения.

2. Ядерная оценка плотности (KDE) на непрерывных распределениях

В отличие от ступенчатых гистограмм, ядерная оценка (с использованием гауссова ядра) формирует непрерывную и дифференцируемую кривую. Однако качество этой аппроксимации сильно зависит от природы самого распределения:

- а. Нормальное распределение: Является идеальным случаем для гауссова ядра. Если при $n = 20$ наблюдаются искажения формы (асимметрия, смещение центра), то при $n = 100$ эмпирическая оценка практически безупречно совпадает с теоретическим «колоколом».
- б. Распределение Лапласа: Выявляет ограничение метода. Теоретическая плотность Лапласа имеет острый, недифференцируемый пик в нуле. Поскольку ядерная оценка строится как сумма гладких функций Гаусса, она математически не способна воспроизвести такой излом. В результате, даже при $n = 100$, эмпирическая кривая на вершине получается более округлой и заниженной по сравнению с теорией.
- в. Равномерное распределение: Демонстрирует так называемый «краевой эффект» (boundary effect). Теоретическая плотность строго обрывается на границах интервала $[-\sqrt{3}, \sqrt{3}]$, принимая значение ноль за их пределами. Однако гауссовы ядра, помещенные в крайние точки выборки, «растекаются» в бесконечность. Из-за этого на графиках KDE мы видим плавные «хвосты», уходящие за пределы допустимого отрезка, сглаживая прямоугольную форму распределения.

3. Ядерная оценка дискретных данных (распределение Пуассона)

Применение непрерывного ядерного сглаживания к дискретному распределению Пуассона создает математическую абстракцию. Алгоритм формирует гладкую кривую, которая визуально работает как огибающая для истинных дискретных вероятностей (красных точек). При $n = 100$ эта огибающая достаточно точно отражает общую форму и колоколообразную симметрию распределения Пуассона (при $\lambda = 10$), доказывая, что KDE можно применять для визуального обобщения дискретных данных, если нас интересует общий тренд, а не точные вероятности в конкретных точках.

4. Проблема параметра сглаживания (Анализ распределения Коши)

Особого внимания заслуживает график влияния ширины окна h на ядерную оценку (Рисунок 11). На нем наглядно раскрывается уязвимость автоматических алгоритмов подбора h . Как было указано в теоретической части, правило Скотта вычисляет h пропорционально выборочному стандартному отклонению $\hat{\sigma}$. Поскольку распределение Коши обладает «тяжелыми хвостами», в выборке регулярно появляются экстремальные выбросы (значения, уходящие далеко за ± 50). Это запускает цепную математическую реакцию:

1. Наличие выбросов приводит к тому, что выборочное стандартное отклонение $\hat{\sigma}$ становится гигантским.

2. Алгоритм Скотта, опираясь на это $\hat{\sigma}$, вычисляет неадекватно большое значение h .
3. Локальные гауссовы ядра становятся слишком широкими.

В результате на центральном графике ($h = 1.0h$ Скотта) мы видим пересглаживание: реальный пик распределения "размазывается", а эмпирическая кривая выглядит неестественно плоской. Увеличение окна в 2.5 раза усугубляет ситуацию, превращая плотность в почти прямую линию. Напротив, искусственное уменьшение окна в 10 раз ($h = 0.1h$) приводит к недосглаживанию: кривая становится зубчатой, так как узкие ядра перестают сливаться друг с другом, и алгоритм начинает моделировать статистический шум вместо общего закона.

Выводы

1. Сходимость ЭФР: Визуально подтверждена теорема Гливленко — Кантелли: с увеличением объема выборки эмпирическая функция распределения равномерно приближается к теоретической.
2. Ограничения ядерного сглаживания: Ядерная оценка плотности (KDE) эффективно решает проблему ступенчатости гистограмм, но имеет свои недостатки. Метод математически не способен точно воспроизвести острые изломы (распределение Лапласа) и подвержен «краевому эффекту», размывая строгие границы (равномерное распределение).
3. Уязвимость к выбросам: Стандартные алгоритмы подбора ширины окна (правило Скотта) опираются на расчет выборочной дисперсии. Эксперимент с распределением Коши доказал, что наличие тяжелых хвостов и экстремальных выбросов многократно завышает дисперсию, заставляя алгоритм выбирать неадекватно большое значение h . Это приводит к сильному пересглаживанию и потере истинной формы плотности, что диктует необходимость ручной калибровки h при работе с аномальными данными.

Список литературы

Электронные ресурсы:

1. Документация `scipy` - <https://docs.scipy.org/doc/scipy/>
2. Документация `seaborn` - <https://seaborn.pydata.org/>

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%204