Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №5:

«Корреляционный анализ и эллипсы рассеивания»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи 3
Теоретическая часть 3
Реализация 5
Результаты 6
Обсуждение 8
Выводы 9
Список литературы 10
Приложение 10

Постановка задачи

Целью данной лабораторной работы является изучение методов корреляционного анализа и освоение способов визуализации ковариационной структуры двумерных статистических данных. Работа открывает второй блок лабораторных исследований, смещая фокус с описательной статистики одномерных распределений на анализ статистических связей между двумя случайными переменными.

Основной задачей исследования выступает количественное и визуальное сопоставление различных мер линейной и монотонной зависимости: классического коэффициента корреляции Пирсона, рангового коэффициента Спирмена и робастного квадрантного коэффициента. Для этого требуется сгенерировать двумерные выборки объемом $n = 20, 60$ и 100. В качестве генеральной совокупности используются двумерное нормальное распределение с заданными истинными коэффициентами корреляции ($\rho = 0, \rho = 0.5, \rho = 0.9$), а также специальная вероятностная модель — «смесь» распределений, где 10% выборки составляют аномальные данные (выбросы) с противоположной корреляционной зависимостью.

Для объективной оценки статистических свойств рассматриваемых коэффициентов применяется метод Монте-Карло. Процедура генерации выборок и вычисления трех коэффициентов корреляции повторяется 1000 раз, после чего для каждого коэффициента вычисляется эмпирическое математическое ожидание и дисперсия. Это позволит проанализировать эффективность оценок на "чистых" нормальных данных и доказать неустойчивость коэффициента Пирсона к наличию выбросов (модель смеси). Дополнительной, но не менее важной задачей является визуальный анализ формы двумерных распределений. Для каждой комбинации параметров необходимо построить диаграммы рассеяния (scatter plots) с наложением эллипсов равновероятности, иллюстрирующих направление и тесноту линейной связи между переменными в зависимости от объема данных и истинного значения ρ.

Теоретическая часть

В математической статистике для количественной оценки тесноты и направления связи между двумя случайными величинами X и Y применяются коэффициенты корреляции. Значения этих коэффициентов всегда лежат в диапазоне [-1, 1]. Значение $+1$ указывает на строгую прямую (положительную) зависимость, -1 - на строгую обратную (отрицательную), а 0 свидетельствует об отсутствии линейной взаимосвязи. В данной работе исследуются три различных подхода к оценке корреляции, отличающиеся своей устойчивостью к аномальным данным.

Классической мерой является выборочный коэффициент корреляции Пирсона (r_{xy}). Он оценивает исключительно линейную зависимость и вычисляется через выборочную ковариацию, нормированную на произведение выборочных среднеквадратичных отклонений:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2 \sum_{i=1}^{n}(y_i - \overline{y})^2}}$$

Коэффициент Пирсона является оптимальной (наиболее эффективной) оценкой для данных, имеющих строго двумерное нормальное распределение. Однако он обладает крайне низкой робастностью: появление в выборке даже единичных грубых выбросов способно кардинально исказить его значение.

Для преодоления проблемы выбросов применяются непараметрические ранговые оценки. Коэффициент корреляции Спирмена (ρ_S) вычисляется аналогично коэффициенту Пирсона, но не для самих значений выборки, а для их рангов (порядковых номеров в отсортированном массиве). Переход к рангам позволяет оценивать не только линейную, но и любую монотонную зависимость, а также существенно снижает влияние экстремальных значений, так как амплитуда выброса игнорируется - учитывается лишь его крайняя позиция в ряду.

Наибольшей робастностью обладает квадрантный коэффициент корреляции ($\hat{\mathrm{q}}$). Для его вычисления координатная плоскость разбивается на четыре квадранта прямыми $x = med(x)$ и $y = med(y)$, проходящими через выборочные медианы. Коэффициент вычисляется на основе знаков отклонений элементов от медианного центра:

$$\hat{\mathrm{q}} = \frac{1}{n}\sum_{i=1}^{n} sign\big(x_i - med(x)\big) \cdot sign\big(y_i - med(y)\big)$$

Этот метод полностью игнорирует абсолютные значения расстояний, реагируя только на то, в какой геометрической четверти оказалась точка.

Для проверки робастности оценок в работе используется модель Тьюки — «смесь» распределений. Она представляет собой базовое нормальное распределение с высокой положительной корреляцией ($\rho = 0.9$), в которое искусственно добавлено 10% «загрязняющих» данных (выбросов) с огромной дисперсией и противоположной корреляцией ($\rho = -0.9$). Эта модель имитирует реальные ситуации сбоя измерительной аппаратуры.

Визуальный анализ двумерных данных осуществляется с помощью диаграмм рассеяния и эллипсов равновероятности. Эллипс рассеивания геометрически отображает структуру ковариационной матрицы выборки. Его центр совпадает с точкой выборочных

средних $(\overline{x}, \overline{y})$. Направление главных осей эллипса задается собственными векторами ковариационной матрицы, а длины полуосей пропорциональны корням из её собственных значений. Угол наклона большой оси эллипса указывает на знак корреляции, а степень его «сжатия» (эксцентриситет) визуализирует тесноту связи: чем у́же эллипс, тем ближе коэффициент корреляции к единице по модулю.

Реализация

Разработка выполнена на языке Python с использованием стека библиотек для научных вычислений: `numpy`, `scipy.stats`, `pandas` и `matplotlib`. Для обеспечения повторяемости результатов статистических экспериментов в начале скрипта строго фиксируется состояние генератора псевдослучайных чисел (seed).

Генерация двумерных нормально распределенных выборок осуществляется с помощью встроенной функции `np.random.multivariate_normal`, принимающей на вход нулевой вектор математических ожиданий и ковариационную матрицу, которая формируется динамически на основе заданного параметра ρ. Стохастическая модель «смеси» реализована алгоритмически: с использованием равномерного распределения и логического маскирования 90% массива заполняется значениями базового распределения ($\rho = 0.9, \sigma^2 = 1$), а оставшиеся 10% аномальными значениями выбросов с противоположной корреляцией ($\rho = -0.9$) и увеличенной дисперсией ($\sigma^2 = 100$).

Вычисление классического коэффициента Пирсона и рангового коэффициента Спирмена выполняется оптимизированными методами `pearsonr` и `spearmanr` из модуля `scipy.stats`. Поскольку расчет квадрантного коэффициента корреляции не представлен в стандартных библиотеках, для него написана пользовательская функция, использующая векторизованные математические операции нахождения медианы (`np.median`) и извлечения знака (`np.sign`). Сбор статистических данных (метод Монте-Карло) производится в цикле из 1000 итераций, после чего полученные массивы коэффициентов усредняются для нахождения эмпирического математического ожидания и дисперсии. Итоговые значения сводятся в отчетные таблицы средствами библиотеки `pandas`.

Визуализация диаграмм рассеяния реализована методом `ax.scatter`. Для строгого математического построения эллипсов равновероятности скрипт вычисляет эмпирическую ковариационную матрицу для каждой сгенерированной выборки. Посредством функции `np.linalg.eigh` (разложение Эрмитовых матриц) находятся собственные значения и собственные векторы ковариационной матрицы, которые однозначно задают длины полуосей и угол наклона эллипса соответственно. Во избежание геометрических искажений эллипсов при выводе на экран, пропорции координатных осей принудительно выравниваются параметром `set_aspect('equal')`.

Результаты

```
========================= Таблица для n = 20 =========================
         Pearson μ Pearson σ² Spearman μ Spearman σ² Quadrant μ Quadrant σ²
p=0       0.006004   0.053131   0.004872    0.051970   0.000400    0.051520
p=0.5     0.491103   0.030937   0.462060    0.034805   0.321600    0.048413
p=0.9     0.897178   0.002412   0.869180    0.004740   0.709200    0.028795
mixture  -0.337339   0.429870   0.472869    0.076100   0.536400    0.036675


========================= Таблица для n = 60 =========================
         Pearson μ Pearson σ² Spearman μ Spearman σ² Quadrant μ Quadrant σ²
p=0       0.001342   0.016472   0.000773    0.016852  -0.000733    0.016795
p=0.5     0.497024   0.009545   0.477413    0.010585   0.327333    0.014355
p=0.9     0.897275   0.000708   0.880963    0.001196   0.701133    0.009012
mixture  -0.651183   0.083449   0.464754    0.025440   0.552200    0.010697


========================= Таблица для n = 100 =========================
         Pearson μ Pearson σ² Spearman μ Spearman σ² Quadrant μ Quadrant σ²
p=0       0.000929   0.010428   0.000807    0.010316   0.003400    0.009843
p=0.5     0.501520   0.005784   0.481260    0.006235   0.333760    0.008611
p=0.9     0.897945   0.000377   0.884716    0.000629   0.705720    0.005183
mixture  -0.691978   0.032088   0.480824    0.015575   0.561760    0.006672
```

Рисунок 1: Результаты вычислений коэффициентов корреляций

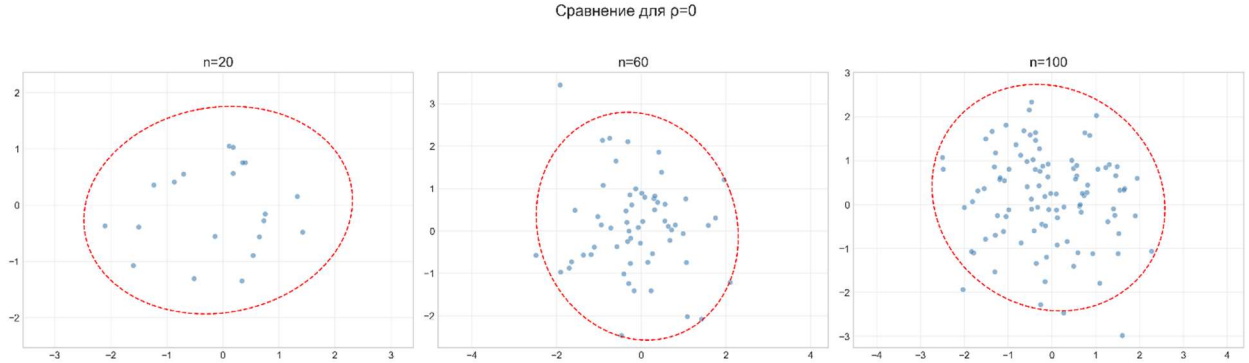

Рисунок 2: Диаграммы рассеиваний и эллипсы равновероятностей при ρ = 0

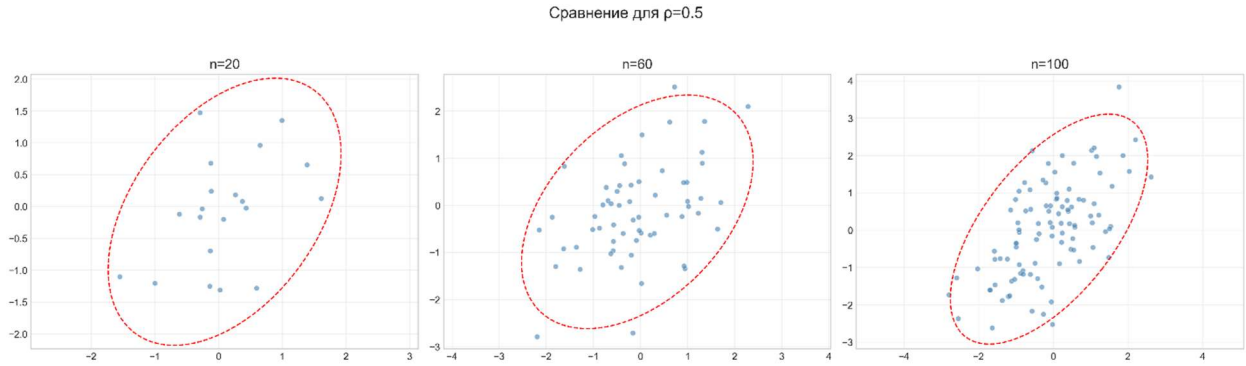

Рисунок 3: Диаграммы рассеиваний и эллипсы равновероятностей при ρ = 0.5

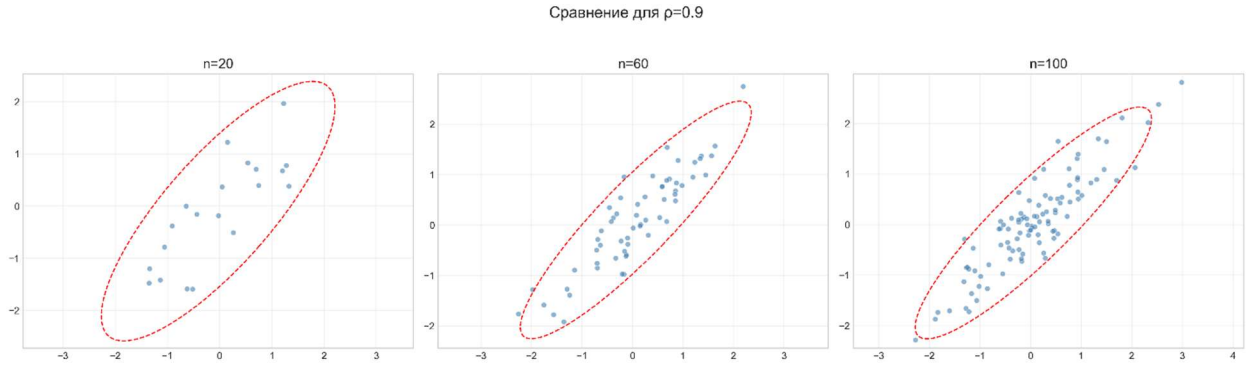

Рисунок 4: Диаграммы рассеиваний и эллипсы равновероятностей при ρ = 0.9

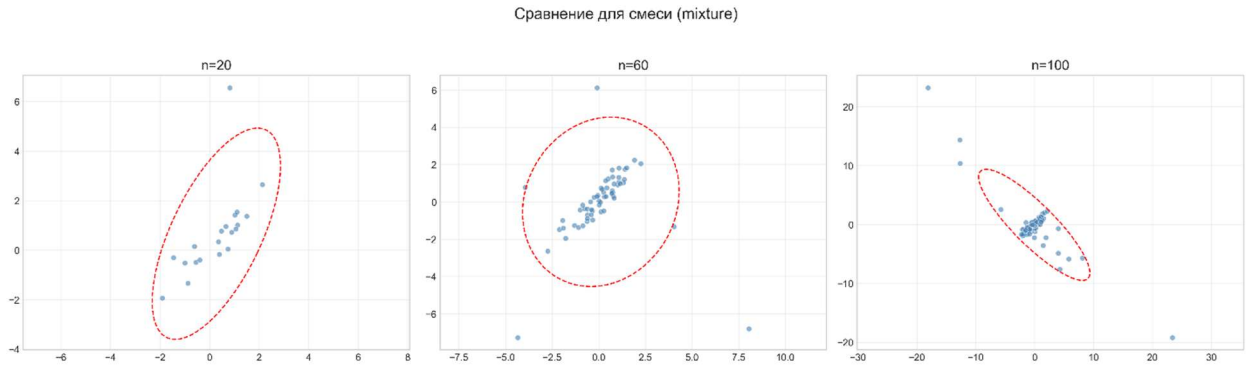

Рисунок 5: Диаграммы рассеиваний и эллипсы равновероятностей для смеси

Обсуждение

Анализ полученных расчетных таблиц и визуальных диаграмм рассеяния позволяет комплексно оценить поведение различных мер корреляции и их устойчивость к структуре данных.

В первую очередь, результаты эксперимента наглядно подтверждают действие закона больших чисел. При анализе таблиц для «чистых» нормальных распределений ($\rho = 0, 0.5, 0.9$) четко прослеживается тенденция: по мере увеличения объема выборки n от 20 до 100 эмпирическая дисперсия (σ^2) всех трех коэффициентов корреляции закономерно уменьшается, а их математические ожидания (μ) стабилизируются. При этом на данных без аномалий классический коэффициент Пирсона ожидаемо демонстрирует наивысшую статистическую эффективность (его дисперсия минимальна). Стоит отметить важную математическую особенность: значения рангового коэффициента Спирмена и квадрантного коэффициента для $\rho = 0.5$ и $\rho = 0.9$ оказываются ниже коэффициента Пирсона (например, квадрантный коэффициент дает ≈ 0.33 при истинном $\rho = 0.5$). Это не является ошибкой; данные коэффициенты оценивают монотонную связь иначе и теоретически сходятся не к ρ, а к значениям $\frac{6}{\pi} arcsin\left(\frac{\rho}{2}\right)$ и $\frac{2}{\pi} arcsin(\rho)$ соответственно, что безупречно подтверждается нашими табличными данными.

Геометрическая интерпретация на графиках полностью согласуется с табличными вычислениями. Для независимых величин ($\rho = 0$) облако точек образует симметричное пятно, а построенный эллипс равновероятности стремится к форме окружности, оси которой параллельны осям координат. При появлении зависимости ($\rho = 0.5$) эллипс вытягивается и наклоняется вдоль главной диагонали. Для сильной корреляции ($\rho = 0.9$) облако точек плотно группируется вдоль прямой линии, а эллипс приобретает форму узкого вытянутого овала, что визуально подтверждает высокую тесноту линейной связи. На этих графиках хорошо видно, как увеличение n делает контуры эллипса более стабильными и точными.

Особый научный и практический интерес представляет модель «смеси» (mixture), которая служит жестким стресс-тестом на робастность. На графиках для смеси мы видим парадоксальную картину: абсолютное большинство точек (90%) образует плотное, вытянутое ядро с сильной положительной корреляцией (как при $\rho = 0.9$). Однако наличие всего 10% экстремальных выбросов, расположенных далеко во второй и четвертой координатных четвертях, полностью разрушает классическую аналитику.

Визуально этот крах демонстрирует красный эллипс рассеивания. Поскольку его расчет базируется на ковариационной матрице (как и коэффициент Пирсона), квадратичные отклонения выбросов вносят колоссальный вклад в расчеты. На графике для $n =$

100 (смесь) видно, что эллипс не охватывает плотное ядро, а неестественно раздувается и наклоняется в отрицательную сторону, пытаясь «захватить» далекие выбросы.

Табличные данные подтверждают визуальную катастрофу Пирсона: вместо выявления сильной положительной связи основного массива данных, его математическое ожидание уходит в глубокий минус (до -0.69 при $n = 100$), а дисперсия возрастает на порядки. Метод Пирсона оказался абсолютно несостоятельным при наличии аномалий. В блестящем противовесе выступают непараметрические оценки. Квадрантный коэффициент и коэффициент Спирмена, опирающиеся на знаки и ранги соответственно, проигнорировали гигантскую амплитуду выбросов. В таблицах видно, что для модели смеси они сохранили положительные значения ($\mu \approx 0.48 \ldots 0.56$), достоверно указав на то, что преобладающая часть выборки имеет прямую зависимость.

Таким образом, результаты лабораторной работы доказывают, что классический корреляционный анализ (Пирсон и ковариационные эллипсы) эффективен только на идеально «чистых» нормальных данных. В реальных задачах, где возможны сбои измерений и грубые выбросы, слепое доверие коэффициенту Пирсона может привести к диаметрально неверным выводам, что делает обязательным использование робастных методов оценки (квадрантный коэффициент) и визуального контроля данных.

Выводы

1. Эффективность на «чистых» данных: Для строго нормального двумерного распределения без аномалий классический коэффициент Пирсона является наилучшей (наиболее эффективной) оценкой, демонстрируя наименьшую дисперсию. Построенные на этих данных эллипсы рассеивания адекватно и точно визуализируют тесноту и направление линейной связи.
2. Неробастность классических методов: Коэффициент Пирсона и ковариационные эллипсы критически уязвимы к статистическим аномалиям. Эксперимент с моделью «смеси» доказал, что наличие всего 10% грубых выбросов полностью разрушает классический анализ, неестественно искажая эллипс и меняя знак корреляции на противоположный.
3. Надежность робастных оценок: В условиях реальных или «загрязненных» данных достоверный результат обеспечивают только робастные характеристики. Коэффициент Спирмена (опирающийся на ранги) и квадрантный коэффициент (опирающийся на знаки) успешно нивелируют амплитуду экстремальных выбросов и корректно выявляют истинную зависимость основного массива наблюдений.

Список литературы

Электронные ресурсы:

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/
2. Документация `seaborn` - https://seaborn.pydata.org/

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%205