

Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №6:

«Линейная регрессия. Метод наименьших квадратов и наименьших модулей»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи	3
Теоретическая часть	3
Реализация	5
Результаты.....	6
Обсуждение	7
Выводы.....	8
Список литературы	9
Приложение	9

Постановка задачи

Целью данной лабораторной работы является изучение базовых методов восстановления регрессионной зависимости и исследование их математической робастности (устойчивости) к наличию аномальных значений в обучающей выборке. В рамках работы рассматривается классическая задача одномерной линейной регрессии, где восстанавливается неизвестная зависимость вида $y = a + bx$.

Для проведения исследования генерируется базовая равномерная сетка переменной x , состоящая из 20 точек на отрезке $[-1.8, 2]$. Значения зависимой переменной y моделируются на основе истинной линейной функции с параметрами $a = 2$ и $b = 2$ с добавлением аддитивного белого гауссовского шума $\varepsilon \sim N(0,1)$. На основе полученной «чистой» выборки требуется вычислить эмпирические оценки параметров a и b с помощью двух принципиально различных целевых функций: классического метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ).

Центральной задачей работы является стресс-тестирование данных методов. Для этого в базовую выборку искусственно вносятся грубые искажения: первое и последнее значения зависимой переменной (y_1 и y_{20}) изменяются на $+10$ и -10 соответственно. На этой «загрязненной» выборке процедура оценки параметров МНК и МНМ повторяется.

Результаты работы должны быть представлены в виде совмещенных графиков, на которых отображаются сгенерированные точки, истинная прямая и две эмпирические регрессионные прямые (для выборки с выбросами и без них). Также требуется рассчитать абсолютные (Δ) и относительные ($\delta, \%$) погрешности вычисленных параметров относительно истинных значений и свести их в сравнительные таблицы, что позволит количественно обосновать разницу в поведении двух методов оптимизации.

Теоретическая часть

Задача линейной регрессии заключается в поиске параметров $\hat{a}$ и $\hat{b}$, при которых эмпирическая прямая $y = \hat{a} + \hat{b}x$ наилучшим образом аппроксимирует имеющийся набор данных (x_i, y_i) . Качество аппроксимации определяется функцией потерь, минимизация которой и является математической сутью алгоритма обучения.

Исторически первым и наиболее распространенным подходом является метод наименьших квадратов. В его основе лежит минимизация суммы квадратов отклонений (остатков) эмпирических значений от теоретической прямой:

$$Q(\hat{a}, \hat{b}) = \sum_{i=1}^n (y_i - (\hat{a} + \hat{b}x_i))^2 \rightarrow \min$$

С точки зрения математической статистики, оценки МНК полностью совпадают с оценками метода максимального правдоподобия (ММП) при условии, что ошибки наблюдения ε_i независимы и подчиняются нормальному закону распределения $N(0, \sigma^2)$.

Поскольку функция $Q(\hat{a}, \hat{b})$ является непрерывной и строго выпуклой, необходимые условия экстремума сводятся к равенству нулю ее частных производных по оцениваемым параметрам:

$$\begin{cases} \frac{\partial Q}{\partial \hat{a}} = -2 \sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i) = 0 \\ \frac{\partial Q}{\partial \hat{b}} = -2 \sum_{i=1}^n x_i (y_i - \hat{a} - \hat{b}x_i) = 0 \end{cases}$$

Раскрывая скобки и деля на n , мы получаем классическую систему нормальных уравнений:

$$\begin{cases} \hat{a} + \hat{b}\bar{x} = \bar{y} \\ \hat{a}\bar{x} + \hat{b}\bar{x}^2 = \bar{x}\bar{y} \end{cases}$$

где $\bar{x}, \bar{y}$ - выборочные средние, а $\bar{x}\bar{y}$ - выборочное среднее произведений. Решая данную систему аналитически, получаем явные формулы для оценок параметров:

$$\hat{b} = \frac{\bar{x}\bar{y} - \bar{x} \cdot \bar{y}}{\bar{x}^2 - (\bar{x})^2}, \hat{a} = \bar{y} - \hat{b}\bar{x}$$

Как видно из формул, оценка углового коэффициента $\hat{b}$ есть отношение выборочной ковариации к выборочной дисперсии признака x . Наличие квадратичных терминов в знаменателе и числителе математически объясняет абсолютную неустойчивость (неробастность) МНК к аномальным выбросам.

Альтернативным подходом является метод наименьших модулей (МНМ), который минимизирует сумму абсолютных отклонений:

$$L(\hat{a}, \hat{b}) = \sum_{i=1}^n |y_i - (\hat{a} + \hat{b}x_i)| \rightarrow \min$$

С вероятностной точки зрения, оценки МНМ эквивалентны оценкам метода максимального правдоподобия в предположении, что ошибки ε_i имеют распределение Лапласа. Это распределение обладает «тяжелыми хвостами», что математически обосновывает устойчивость МНМ к экстремальным выбросам.

В отличие от МНК, функция модуля не является дифференцируемой в нуле. Если формально взять производные (там, где они существуют), мы получим уравнения, содержащие функцию знака (*sign*):

$$\sum_{i=1}^n \text{sign}(y_i - \hat{a} - \hat{b}x_i) = 0, \sum_{i=1}^n x_i \text{sign}(y_i - \hat{a} - \hat{b}x_i) = 0$$

Из первого уравнения следует, что прямая МНМ должна делить выборку так, чтобы количество точек выше и ниже прямой было примерно одинаковым. Таким образом, оценка МНМ является своеобразным обобщением медианы на двумерный случай. Вследствие присутствия функции *sign*, система не имеет простого аналитического решения в виде явных формул для $\hat{a}$ и $\hat{b}$, что вынуждает использовать для нахождения оценок итеративные численные методы. Однако именно этот факт делает МНМ исключительно робастным: любой выброс y_i входит в уравнение только своим знаком, а не абсолютной величиной или ее квадратом, что не позволяет аномалии «перетянуть» прямую на себя.

Сравнение методов осуществляется через расчет абсолютной (Δ) и относительной (δ) погрешностей для каждого коэффициента по формулам:

$$\Delta z = |z - \hat{z}|$$

$$\delta z = \frac{|z - \hat{z}|}{z} \cdot 100\%$$

где z - истинное значение параметра (в данной работе $z \in \{2,2\}$), $\hat{z}$ - а приближенное значение, вычисленное методами МНК или МНМ.

Реализация

Разработка выполнена на языке Python с использованием библиотек `numpy`, `scipy.optimize`, `pandas` и `matplotlib`. В начале скрипта фиксируется зерно генератора случайных чисел для обеспечения воспроизводимости данных. Генерация независимой переменной x реализована функцией `np.linspace`, создающей равномерную сетку из 20 точек. Зависимая переменная y вычисляется с помощью векторизованных операций на основе заданных истинных коэффициентов с добавлением нормально распределенного шума `np.random.normal`. Для формирования выборки с выбросами массив y копируется, после чего к его первому и последнему элементам (по индексам 0 и 19) искусственно прибавляются и вычитаются константы согласно заданию.

Программная реализация двух методов регрессии принципиально отличается из-за их математической природы. Для метода наименьших квадратов (МНК) используется встроенная функция `np.polyfit(x, y, 1)`. Эта функция под капотом использует

матричные операции (сингулярное разложение) для быстрого и точного аналитического решения системы уравнений, минимизируя L2-норму ошибки.

В отличие от МНК, метод наименьших модулей (МНМ) не имеет точного аналитического решения. Для его реализации написана пользовательская функция, внутри которой задана целевая функция потерь — сумма модулей отклонений (L1-норма). Поиск оптимальных параметров a и b осуществляется численно с помощью функции `minimize` из модуля `scipy.optimize`. В качестве алгоритма минимизации используется симплекс-метод Нелдера - Мида (`method='Nelder-Mead'`), который хорошо работает с недифференцируемыми функциями (каковой является модуль). Для ускорения сходимости алгоритма в качестве начального приближения (`initial_guess`) в оптимизатор передаются параметры, предварительно найденные методом МНК.

После нахождения коэффициентов для обеих выборок («чистой» и «загрязненной»), программа по заданным формулам вычисляет абсолютные и относительные погрешности, формирует из них наглядные таблицы средствами библиотеки `pandas` и генерирует два совмещенных графика регрессионных прямых с использованием `matplotlib`.

Результаты

===== ВЫБОРКА БЕЗ ВЫБРОСОВ =====						
	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
Метод						
МНК	1.878	0.122	6.08	1.502	0.498	24.89
МНМ	1.709	0.291	14.54	1.562	0.438	21.88
===== ВЫБОРКА С ВЫБРОСАМИ =====						
	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
Метод						
МНК	2.021	0.021	1.07	0.074	1.926	96.32
МНМ	1.817	0.183	9.13	1.407	0.593	29.65

Рисунок 1: Оценка погрешностей найденных значений параметров при отсутствии и наличии выбросов




Рисунок 2: Результаты аппроксимации при отсутствии и наличии выбросов

Обсуждение

Анализ результатов, представленных на графиках и в расчетных таблицах, наглядно демонстрирует фундаментальные различия в поведении метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ) при решении задачи линейной регрессии.

На левом графике («Выборка без аномалий») представлена ситуация, приближенная к идеальным теоретическим условиям, где шум имеет нормальное распределение и отсутствуют экстремальные выбросы. Визуально обе эмпирические прямые (красная пунктирная для МНК и синяя штрихпунктирная для МНМ) проходят очень близко друг к другу и достаточно хорошо аппроксимируют истинную зависимость (черную сплошную линию). Обращаясь к табличным данным для чистой выборки, можно заметить, что МНК справляется с задачей несколько лучше: относительная погрешность определения параметра a (свободного члена) составляет 6.08% против 14.54% у МНМ. Погрешности определения углового коэффициента b у методов сопоставимы ($\approx 21 - 24\%$). Этот результат полностью согласуется с теоремой Гаусса — Маркова, согласно которой МНК дает наилучшие (наиболее эффективные) оценки при нормальном распределении ошибок.

Однако картина радикально меняется на правом графике («Выборка с выбросами»), где в данные искусственно внесены два грубых искажения на концах интервала наблюдения. Наличие всего двух аномальных точек приводит к катастрофическому искажению оценки МНК. Красная пунктирная линия практически полностью теряет наклон, становясь горизонтальной. Это происходит из-за квадратичной природы функции потерь: алгоритм пытается минимизировать квадрат огромного отклонения на концах отрезка, жертвуя точностью аппроксимации всех остальных, "правильных" точек.

Табличные расчеты для выборки с выбросами подтверждают визуальный крах МНК: угловой коэффициент b падает с истинного значения 2.0 до 0.074, что соответствует

колоссальной относительной погрешности в 96.32%. Метод наименьших квадратов показал абсолютную неробастность (неустойчивость).

В блестящем противовесе выступает метод наименьших модулей (МНМ). На правом графике синяя штрихпунктирная линия практически не изменила своего положения по сравнению с чистой выборкой, продолжая уверенно следовать вдоль истинной черной прямой. Линейный характер штрафа за отклонение (L1-норма) позволяет алгоритму игнорировать экстремальные выбросы, так как их «вес» не возводится в квадрат. Согласно таблице, относительная погрешность углового коэффициента b для МНМ составила 29.65%, что всего на 8% хуже, чем на идеально чистой выборке, и в три раза точнее, чем у МНК в условиях аномалий.

Подводя итог, проведенный эксперимент убедительно доказывает, что выбор метода оптимизации критически зависит от качества данных. При работе с надежными измерениями, содержащими лишь естественный белый шум, предпочтителен МНК ввиду его высокой эффективности и простоты вычислений. Однако в реальных задачах, где существует риск появления грубых ошибок или сбоев датчиков, использование МНК может привести к построению в корне неверной модели. В таких случаях необходимо применять робастные алгоритмы, ярким представителем которых является метод наименьших модулей.

Выводы

1. Эффективность на «чистых» данных: На выборках с нормально распределенным шумом без аномалий метод наименьших квадратов (МНК) показывает наилучшую точность, обеспечивая минимальную погрешность восстановления параметров линейной регрессии.
2. Критическая уязвимость МНК: Метод абсолютно неробастен. Из-за квадратичной функции потерь появление в данных даже единичных грубых выбросов приводит к катастрофическому искажению регрессионной прямой (относительная ошибка углового коэффициента превысила 96%).
3. Робастность МНМ: Метод наименьших модулей (МНМ) обладает высокой устойчивостью к аномалиям. Благодаря линейному штрафу (L1-норме) алгоритм успешно игнорирует экстремальные отклонения и достоверно восстанавливает истинную зависимость даже на сильно «загрязненных» данных.

Список литературы

Электронные ресурсы:

1. Документация `scipy` - <https://docs.scipy.org/doc/scipy/>
2. Документация `seaborn` - <https://seaborn.pydata.org/>

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%206