Санкт-Петербургский политехнический университет Петра Великого

Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Направление подготовки

01.03.02 «Прикладная математика и информатика»

Дисциплина «Математическая статистика»

Отчет по лабораторной работе №6:

«Линейная регрессия. Метод наименьших квадратов и наименьших модулей»

Работу выполнил:

Архиповский А. М., 5030102/30202

Преподаватель:

Баженов А. С.

Санкт-Петербург

2026

Оглавление

Постановка задачи 3
Теоретическая часть 3
Реализация 4
Результаты 5
Обсуждение 6
Выводы 7
Список литературы 8
Приложение 8

Постановка задачи

Целью данной лабораторной работы является изучение базовых методов восстановления регрессионной зависимости и исследование их математической робастности (устойчивости) к наличию аномальных значений в обучающей выборке. В рамках работы рассматривается классическая задача одномерной линейной регрессии, где восстанавливается неизвестная зависимость вида $y = a + bx$.

Для проведения исследования генерируется базовая равномерная сетка переменной x, состоящая из 20 точек на отрезке $[-1.8, 2]$. Значения зависимой переменной y моделируются на основе истинной линейной функции с параметрами $a = 2$ и $b = 2$ с добавлением аддитивного белого гауссовского шума $\varepsilon \sim N(0,1)$. На основе полученной «чистой» выборки требуется вычислить эмпирические оценки параметров a и b с помощью двух принципиально различных целевых функций: классического метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ).

Центральной задачей работы является стресс-тестирование данных методов. Для этого в базовую выборку искусственно вносятся грубые искажения: первое и последнее значения зависимой переменной (y_1 и y_{20}) изменяются на $+10$ и -10 соответственно. На этой «загрязненной» выборке процедура оценки параметров МНК и МНМ повторяется.

Результаты работы должны быть представлены в виде совмещенных графиков, на которых отображаются сгенерированные точки, истинная прямая и две эмпирические регрессионные прямые (для выборки с выбросами и без них). Также требуется рассчитать абсолютные (Δ) и относительные ($\delta, \%$) погрешности вычисленных параметров относительно истинных значений и свести их в сравнительные таблицы, что позволит количественно обосновать разницу в поведении двух методов оптимизации.

Теоретическая часть

Задача линейной регрессии заключается в поиске параметров $\hat{a}$ и $\hat{b}$, при которых эмпирическая прямая $y = \hat{a} + \hat{b}x$ наилучшим образом аппроксимирует имеющийся набор данных (x_i, y_i). Качество аппроксимации определяется функцией потерь, минимизация которой и является математической сутью алгоритма обучения.

Исторически первым и наиболее распространенным подходом является метод наименьших квадратов (МНК). В его основе лежит минимизация суммы квадратов отклонений (остатков) эмпирических значений от теоретической прямой:

$$L_{\text{МНК}} = \sum_{i=1}^{n} \left(y_i - \left(\hat{a} + \hat{b}x_i\right)\right)^2 \to min$$

Метод обладает прекрасными математическими свойствами: функция строго выпукла и имеет аналитическое решение через систему нормальных уравнений (или матричное псевдообращение). По теореме Гаусса — Маркова оценки МНК являются оптимальными (несмещенными и эффективными), но только при условии, что шум в данных имеет строго нормальное распределение. Главным недостатком МНК является его крайняя чувствительность к выбросам (неробастность). Из-за квадратичной функции потерь одна далекая точка дает колоссальный штраф, заставляя алгоритм радикально менять наклон прямой, чтобы скомпенсировать это отклонение.

Альтернативным подходом является метод наименьших модулей (МНМ), который минимизирует сумму абсолютных отклонений:

$$L_{\text{МНМ}} = \sum_{i=1}^{n} \left| y_i - \left(\hat{\text{a}} + \hat{\text{b}} x_i \right) \right| \to min$$

В отличие от МНК, данная целевая функция не имеет простого аналитического решения и требует применения итеративных численных методов оптимизации (например, градиентного спуска или симплекс-метода). Однако линейный характер штрафа делает МНМ исключительно робастной оценкой. Метод опирается на медианные тенденции данных: экстремально большие отклонения (выбросы) штрафуются строго пропорционально их величине (без возведения в квадрат), благодаря чему они не способны «перетянуть» на себя регрессионную прямую.

Сравнение методов осуществляется через расчет абсолютной (Δ) и относительной (δ) погрешностей для каждого коэффициента по формулам:

$$\Delta z = |z - \hat{\text{z}}|$$

$$\delta z = \frac{|z - \hat{\text{z}}|}{z} \cdot 100\%$$

где z - истинное значение параметра (в данной работе $z \in \{2{,}2\}$), $\hat{\text{z}}$ - а приближенное значение, вычисленное методами МНК или МНМ.

Реализация

Разработка выполнена на языке Python с использованием библиотек `numpy`, `scipy.optimize`, `pandas` и `matplotlib`. В начале скрипта фиксируется зерно генератора случайных чисел для обеспечения воспроизводимости данных. Генерация независимой переменной x реализована функцией `np.linspace`, создающей равномерную сетку из 20 точек. Зависимая переменная y вычисляется с помощью векторизованных операций на основе заданных истинных коэффициентов с добавлением нормально распределенного шума `np.random.normal`. Для формирования выборки с выбросами

массив y копируется, после чего к его первому и последнему элементам (по индексам 0 и 19) искусственно прибавляются и вычитаются константы согласно заданию.

Программная реализация двух методов регрессии принципиально отличается из-за их математической природы. Для метода наименьших квадратов (МНК) используется встроенная функция `np.polyfit(x, y, 1)`. Эта функция под капотом использует матричные операции (сингулярное разложение) для быстрого и точного аналитического решения системы уравнений, минимизируя L2-норму ошибки.

В отличие от МНК, метод наименьших модулей (МНМ) не имеет точного аналитического решения. Для его реализации написана пользовательская функция, внутри которой задана целевая функция потерь — сумма модулей отклонений (L1-норма). Поиск оптимальных параметров a и b осуществляется численно с помощью функции minimize из модуля `scipy.optimize`. В качестве алгоритма минимизации используется симплекс-метод Нелдера - Мида (`method='Nelder-Mead'`), который хорошо работает с недифференцируемыми функциями (каковой является модуль). Для ускорения сходимости алгоритма в качестве начального приближения (`initial_guess`) в оптимизатор передаются параметры, предварительно найденные методом МНК.

После нахождения коэффициентов для обеих выборок («чистой» и «загрязненной»), программа по заданным формулам вычисляет абсолютные и относительные погрешности, формирует из них наглядные таблицы средствами библиотеки `pandas` и генерирует два совмещенных графика регрессионных прямых с использованием `matplotlib`.

Результаты

```
==================== ВЫБОРКА БЕЗ ВЫБРОСОВ ====================
           a    Δ a  δ a, %      b    Δ b  δ b, %
Метод
МНК    1.878  0.122    6.08  1.502  0.498   24.89
МНМ    1.709  0.291   14.54  1.562  0.438   21.88


==================== ВЫБОРКА С ВЫБРОСАМИ ====================
           a    Δ a  δ a, %      b    Δ b  δ b, %
Метод
МНК    2.021  0.021    1.07  0.074  1.926   96.32
МНМ    1.817  0.183    9.13  1.407  0.593   29.65
```

Рисунок 1: Оценка погрешностей найденных значений параметров при отсутствии и наличии выбросов

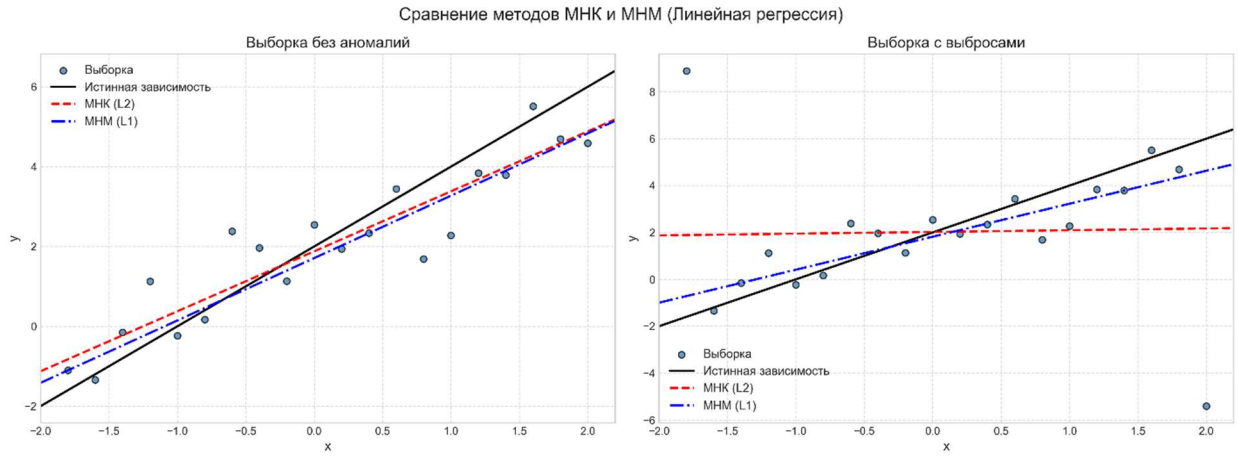

Рисунок 2: Результаты аппроксимации при отсутствии и наличии выбросов

Обсуждение

Анализ результатов, представленных на графиках и в расчетных таблицах, наглядно демонстрирует фундаментальные различия в поведении метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ) при решении задачи линейной регрессии.

На левом графике («Выборка без аномалий») представлена ситуация, приближенная к идеальным теоретическим условиям, где шум имеет нормальное распределение и отсутствуют экстремальные выбросы. Визуально обе эмпирические прямые (красная пунктирная для МНК и синяя штрихпунктирная для МНМ) проходят очень близко друг к другу и достаточно хорошо аппроксимируют истинную зависимость (черную сплошную линию). Обращаясь к табличным данным для чистой выборки, можно заметить, что МНК справляется с задачей несколько лучше: относительная погрешность определения параметра a (свободного члена) составляет 6.08% против 14.54% у МНМ. Погрешности определения углового коэффициента b у методов сопоставимы ($\approx 21 - 24\%$). Этот результат полностью согласуется с теоремой Гаусса — Маркова, согласно которой МНК дает наилучшие (наиболее эффективные) оценки при нормальном распределении ошибок.

Однако картина радикально меняется на правом графике («Выборка с выбросами»), где в данные искусственно внесены два грубых искажения на концах интервала наблюдения. Наличие всего двух аномальных точек приводит к катастрофическому искажению оценки МНК. Красная пунктирная линия практически полностью теряет наклон, становясь горизонтальной. Это происходит из-за квадратичной природы функции потерь: алгоритм пытается минимизировать квадрат огромного отклонения на концах отрезка, жертвуя точностью аппроксимации всех остальных, "правильных" точек.

Табличные расчеты для выборки с выбросами подтверждают визуальный крах МНК: угловой коэффициент b падает с истинного значения 2.0 до 0.074, что соответствует

колоссальной относительной погрешности в 96.32%. Метод наименьших квадратов показал абсолютную неробастность (неустойчивость).

В блестящем противовесе выступает метод наименьших модулей (МНМ). На правом графике синяя штрихпунктирная линия практически не изменила своего положения по сравнению с чистой выборкой, продолжая уверенно следовать вдоль истинной черной прямой. Линейный характер штрафа за отклонение (L1-норма) позволяет алгоритму игнорировать экстремальные выбросы, так как их «вес» не возводится в квадрат. Согласно таблице, относительная погрешность углового коэффициента b для МНМ составила 29.65%, что всего на 8% хуже, чем на идеально чистой выборке, и в три раза точнее, чем у МНК в условиях аномалий.

Подводя итог, проведенный эксперимент убедительно доказывает, что выбор метода оптимизации критически зависит от качества данных. При работе с надежными измерениями, содержащими лишь естественный белый шум, предпочтителен МНК ввиду его высокой эффективности и простоты вычислений. Однако в реальных задачах, где существует риск появления грубых ошибок или сбоев датчиков, использование МНК может привести к построению в корне неверной модели. В таких случаях необходимо применять робастные алгоритмы, ярким представителем которых является метод наименьших модулей.

Выводы

1. Эффективность на «чистых» данных: На выборках с нормально распределенным шумом без аномалий метод наименьших квадратов (МНК) показывает наилучшую точность, обеспечивая минимальную погрешность восстановления параметров линейной регрессии.
2. Критическая уязвимость МНК: Метод абсолютно неробастен. Из-за квадратичной функции потерь появление в данных даже единичных грубых выбросов приводит к катастрофическому искажению регрессионной прямой (относительная ошибка углового коэффициента превысила 96%).
3. Робастность МНМ: Метод наименьших модулей (МНМ) обладает высокой устойчивостью к аномалиям. Благодаря линейному штрафу (L1-норме) алгоритм успешно игнорирует экстремальные отклонения и достоверно восстанавливает истинную зависимость даже на сильно «загрязненных» данных.

Список литературы

Электронные ресурсы:

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/
2. Документация `seaborn` - https://seaborn.pydata.org/

Приложение

https://github.com/TToJlkoBHuK/Mathematical_Statistics/tree/main/Lab%206